

# 유전체자료 기반 개인 식별 AI 개발/검증

연세대학교 디지털애널리틱스 융합협동과정


하재훈

## 분석 배경

### 1-1. 유전체 분석

# 01. 분석 배경

## 1-1. 분석 배경




### 유전체 변이

#### 유전체란?

유전체에는 DNA가 포함되어 있음. DNA는 **4가지의 염기(A, T, G, C)**로 이루어져 있으며, 염기가 특정 순서대로 배열되어 우리 몸의 특성을 결정함.

#### 유전체 변이란?

**DNA 특정 위치에 변화가 생긴 것.** 이러한 변이가 생기면 우리 몸이 변이를 어떻게 처리하느냐에 따라 건강이나 특정 질병에 영향을 미칠 수 있음.



**유전체 분석**을 통해 개인별 질병 예측 및 약물 적합도 등을 파악할 수 있으며,  
이는 맞춤형 의료와 헬스케어 서비스로 이어질 수 있음.

# 01. 분석 배경

## 1-2. 분석 목표



### [테라젠바이오]

- 국내 700여 의료 기관들과 해외 40여개국 연구 기관들을 대상으로 **유전체 분석 서비스**를 제공
- 4세대 개인맞춤형 항암신약(NeoAntigen) 개발을 전문으로 하는 글로벌 유전체 분석 서비스 및 Platform 기반 신약개발 기업
- 유전체 기술을 기반으로 맞춤의학을 실현하고, 이를 통해 인류 복지와 건강에 참된 희망과 실질적인 솔루션을 제공하고자 함

### 목표

- 수만개의 유전체 데이터를 분석해 개인을 식별하여 **맞춤형 의료 및 헬스케어 서비스**를 제공할 수 있는 근거를 창출하고자 함
- 이에 **개인 식별**에 가장 기초적인 근간이 되는 **나이, 성별, 인종**을 구분해내는 **AI 모델을 개발하고자 함**

## EDA 및 전처리

2-1. 데이터 확인 및 전처리


2-2. EDA

## 02. EDA 및 전처리

### 2-1. 데이터 확인 및 전처리

#### <VCF 데이터셋>

| 컬럼명       | 설명                                        |
|-----------|-------------------------------------------|
| CHROM     | 변이가 발생한 염색체 이름(번호) (1~22번 염색체, 변이 염색체 7개) |
| POS       | 변이가 발생한 염색체상의 위치                          |
| ID        | 변이에 대한 식별자                                |
| REF       | 참조(Reference) 염기 서열(변이 발생 전 염기 서열)        |
| ALT       | 대체(Alternative) 염기 서열(변이 발생 후 새로운 염기 서열)  |
| QUAL      | 변이의 품질 점수                                 |
| FILTER    | 변이가 특정 필터를 통과했는지 여부                       |
| INFO      | 추가적인 변이 정보                                |
| FORMAT    | 각 샘플에 대한 정보 표현 형식 설명                      |
| GENOTYPES | 각 샘플에 대한 유전형 정보                           |



해당 컬럼이 고유값을 가지므로 '제거'

- QUAL, FILTER : '.'
- INFO : 'PR'
- FORMAT : 'GT'

- 각 행은 특정 염색체 위치에서 발견된 하나의 변이를 나타냄
- 총 행의 개수 : 78,230

## 02. EDA 및 전처리

### 2-1. 데이터 확인 및 전처리

Genotypes는 각 **개인의 변이 형태를 모두 포함**하는 핵심 정보이기 때문에 **개인식별에 가장 적합**하다고 판단.

👉 Genotypes를 분석에 사용하고자 함

**Genotypes** 개체의 특정 유전적 변이 위치(각 변이 ID)에서의 **대립 유전자 조합**

- 0/0 : 두 염기 모두 참조 염기(REF/REF) → 0
- 0/1 : 하나의 참조염기와 하나의 대체염기 (REF/ALT) → 1
- 1/1 : 두 염기 모두 대체 염기 (ALT/ALT) → 2
- ./.: 정보 없음 → 결측치 처리

#### 전처리

- ① 변이 ID별로 **Genotypes가 모두 같은 값을 가지는 경우** 해당 변이 **제거**
- ② **절반 이상의 결측치**를 가지는 변이 **제거**
- ③ **결측치가 절반 이하인 경우, 결측치를 최빈값으로 대체**

#### 최종 데이터

| EID     | rs116587930 | rs116720794 | ... | rs12184325 | rs3131962 |
|---------|-------------|-------------|-----|------------|-----------|
| 1652660 | 0           | 0           | ... | 0          | 0         |
| 2891981 | 1           | 1           | ... | 1          | 1         |
| 4251527 | 0           | 0           | ... | 0          | 0         |
| 3925679 | 0           | 0           | ... | 0          | 0         |

98 x 601,690

EID(Sample) : 98개  
ID(Genotypes) : 601,690개


## 02. EDA 및 전처리

### 2-1. 데이터 확인 및 전처리

#### Label Data

① Gender – Female: 0, Male : 1

| 컬럼명       | 설명          |
|-----------|-------------|
| EID       | 각 샘플의 고유 ID |
| Gender    | 각 샘플의 성별    |
| Ethnicity | 각 샘플의 인종    |
| Age       | 각 샘플의 나이    |



#### 문제 정의

- 라벨간 균형이 잘 맞음
- Binary Classification


## 02. EDA 및 전처리

### 2-1. 데이터 확인 및 전처리

#### Label Data

② Ethnicity – 인종 총 8개

| 컬럼명       | 설명          |
|-----------|-------------|
| EID       | 각 샘플의 고유 ID |
| Gender    | 각 샘플의 성별    |
| Ethnicity | 각 샘플의 인종    |
| Age       | 각 샘플의 나이    |



| 구분        | count |
|-----------|-------|
| British   | 80    |
| Irish     | 4     |
| Caribbean | 4     |
| African   | 4     |
| Pakistani | 3     |
| Other     | 1     |
| Indian    | 1     |
| Chinese   | 1     |

#### 문제 정의

- 라벨간 불균형 매우 심함 (British가 약 81.6%)
- 1개의 샘플만 존재하는 클래스가 있어, 별도의 처리 필요
- Multi-label classification, Anomaly detection


## 02. EDA 및 전처리

### 2-1. 데이터 확인 및 전처리

#### Label Data

#### ③ Age

| 컬럼명       | 설명          |
|-----------|-------------|
| EID       | 각 샘플의 고유 ID |
| Gender    | 각 샘플의 성별    |
| Ethnicity | 각 샘플의 인종    |
| Age       | 각 샘플의 나이    |



|      |       |
|------|-------|
| mean | 56.13 |
| 25%  | 47    |
| 50%  | 50    |
| 75%  | 57    |
| max  | 69    |

#### 문제 정의


- 나이의 분포가 40~60대 사이에만 존재
- 상대적으로 균등한 분포를 나타냄
- Linear Regression

# 02. EDA 및 전처리


## 2-2. EDA

- 실제 타겟 변수에 따라 Clustering이 잘 수행되는지 탐색적 분석을 하고자 함
- Feature selection(Kbest)을 통해 유의미한 변수들을 추출해 PCA 수행 후 시각화

Gender



Age



# 02. EDA 및 전처리


## 2-2. EDA

### Ethnicity

- 클래스간 불균형이 매우 심하기 때문에 도메인 및 Clustering 결과를 기반으로 새로운 클래스로 재정의하는 것이 필요함


#### ① 전체 인종 분류

모든 클래스에 대해 분류



#### ② 인종의 약 80%를 차지하는 British와 그 외로 분류

British, Non-British로 분류




## 02. EDA 및 전처리

### 2-2. EDA

#### Ethnicity

#### ③ 인종적 유사성으로 분류 - 1

1) British, Irish, Indian, Pakistani 2) African, Caribbean 3) Others




※ 참고

- 1) British, Irish : 지리적 근접성 및 반복적인 인구 이동
- 2) African, Caribbean : 대서양 노예 무역을 통한 이주. 카리브해 인구의 대부분은 아프리카계 (Afro-Caribbean people)
- 3) Indian, Pakistani : 1947년 까지 수천 년 동안 하나의 통일된 제국 아래에 존재



#### ④ 인종적 유사성으로 분류 - 2

1) British,Irish 2) African, Caribbean 3) Indian, Pakistani  
유일값(Chinese, Others)은 제외



지리/역사적 배경\*과 분석 결과를 바탕으로 ④번 기준에 따른 3개의 클래스로 예측 수행

## 02. EDA 및 전처리

### 2-2. EDA

Feature selection 방법론을 통해 몇 가지의 유의미한 특성만으로도  
클래스 분류가 효과적으로 이루어질 수 있음을 확인함



GWAS를 통해 통계적으로 유의미한 변수를 도출

# 03

---

## GWAS

3-1. 통계 분석

3-2. 분석 결과

# 03. GWAS

## 3-1. 통계 분석

각 변이와 3개의 종속변수(나이, 인종, 성별)와의 연관성을 검정하여 예측에 **유의미한 변이 ID를 선택**하기 위해 GWAS 실행

### GWAS란?

- GWAS(Genome-wide association study)는 유전체 전반에 걸쳐 수천에서 수백만 개의 유전 변이를 조사하여 **특정 질병이나 특성에 대한 유전적 연관성을 식별**하는 연구 방법
- 유전자 변이와 표현형(질병, 특정 특성 등) 간의 **통계적 연관성**을 분석하여 특정 유전자가 질병 또는 특성에 영향을 미치는지를 확인

### 통계검정

| Y 종속변수 | X 독립변수      | 통계분석법              |
|--------|-------------|--------------------|
| 연속형    | 범주형(2개 범주)  | T-검정, paired T-검정  |
| 연속형    | 범주형(3개 이상)  | 분산분석(ANOVA)        |
| 연속형    | 연속형         | 회귀분석               |
| 연속형    | 혼합(수치형+범주형) | 공분산분석(ANCOVA)      |
| 범주형    | 범주형         | $\chi^2$ 검정 / 로짓분석 |
| 범주형    | 혼합(수치형+범주형) | 로짓분석               |
| 생존시간   | 혼합(수치형+범주형) | 생존분석               |

Age

귀무가설 추가하기

Ethnicity, Gender


### 유의수준

- 보통 통계검정에서 사용하는 유의수준은 0.05, 0.01 등
- GWAS에서는 일반적으로  $5 \times 10^{-8}$  사용
- 완화된 기준으로는  $1 \times 10^{-5}$  를 사용하기도 함

# 03. GWAS

## 3-1. 통계 분석 - Age

ANOVA 분석(Age) 결과




ANOVA 분석 결과, P-value **5e-8** 기준으로 유의미한 변이ID **없음**  
ANOVA 분석 결과, P-value **1e-5** 기준으로 유의미한 변이ID **4개** 발견

# 03. GWAS


## 3-1. 통계 분석 - Age

ANOVA 분석(Age) 결과

P-value 기준 **유의미한** 변이ID



P-value 기준 **유의하지 않은** 변이ID




**유의미한** 변이 ID는 변이에 따라 **나이 분포에 차이가 있는** 반면,  
**유의하지 않은** 변이 ID는 변이에 따른 **나이 분포가 거의 동일**

# 03. GWAS

## 3-1. 통계 분석 - Ethnicity

$\chi^2$  분석(Ethnicity) 결과



$\chi^2$  분석 결과, P-value **5e-8** 기준으로 유의미한 변이ID **13,835**개 발견

$\chi^2$  분석 결과, P-value **1e-5** 기준으로 유의미한 변이ID **26,471**개 발견


# 03. GWAS

## 3-1. 통계 분석 - Ethnicity

$\chi^2$  분석(Ethnicity) 결과

P-value 기준 **유의미한** 변이ID

British/Irish African/Caribbean Indian/Pakistani



P-value 기준 **유의하지 않은** 변이ID

British/Irish African/Caribbean Indian/Pakistani




**유의미한** 변이 ID는 변이에 따라 인종 분류별로 **변이 분포에 차이가 있는** 반면,  
**유의하지 않은** 변이 ID는 변이에 따른 인종 분류별로 **변이 분포가 거의 동일**

# 03. GWAS

## 3-1. 통계 분석 - Gender

$\chi^2$  분석(Gender) 결과




$\chi^2$  분석 결과, P-value 5e-8 기준으로 유의미한 변이ID 없음  
 $\chi^2$  분석 결과, P-value 1e-5 기준으로 유의미한 변이ID 1개 발견

# 03. GWAS

## 3-1. 통계 분석 - Gender

$\chi^2$  분석(Gender) 결과

P-value 기준 **유의미한** 변이ID



P-value 기준 **유의하지 않은** 변이ID



**유의미한** 변이 ID는 변이에 따라 성별 분류별로 **변이 분포에 차이가 있는** 반면,  
**유의하지 않은** 변이 ID는 변이에 따른 성별 분류별로 **변이 분포가 거의 동일**

# 03. GWAS


## 3-2. 분석 결과

- GWAS 분석결과로 추출한 변이로 회귀분석을 수행해 보았으나, 다음과 같은 **한계점**이 존재
  - 유의미한 **변이 개수가 너무 적거나 많아서** 회귀계수 추정이 불안정하게 됨
  - 모형의 성능이 너무 낮거나, 유의미한 회귀계수가 뚜렷하게 나타나지 않는 점이 드러남

### 1. Age

총 4개의 변이


- ✓ MSE = 34
- ✓ R2 = 0.478



### 2. Gender

총 1개의 변이


- ✓ F1 = 0.37
- ✓ Accuracy = 0.533



### 3. Ethnicity

총 26,471개의 변이

- ✓ F1 = 0.95
- ✓ Accuracy = 0.966



### 새로운 방법론 제안

최고 성능을 보장하는 **최소한의 유의미한 변이ID 조합**을 사용하여 최종 모형을 구축하고자 함

## 회귀 분석

4-1. 분석 개요


4-2. 선형 회귀 분석

4-3. 로지스틱 회귀 분석

# 04. 회귀 분석

## 4-1. 분석 개요

- 새로운 회귀 계수 추정 방법론



\*단 99%내 신뢰수준 내에서




\*최적의 변이ID 조합으로  
가장 적합한 회귀 모형 구축

### 피어슨 상관분석이란?

두 변수 간의 선형 관계의 강도와 방향을 나타내는 상관계수를 계산하는 방법

독립 변수들 간의 상관관계를 파악하여, 너무 높은 상관관계를 가진 변수들을 식별하고, 다중공선성 문제를 피하기 위해 이를 제거하고자 함



# 04. 회귀 분석

## 4-1. 선형 회귀 분석 - Age

- Linear Regression

- ① Best top k 변이ID 개수 : 377개
- ② 상관분석 후 상관계수 높은 변이 ID 제거 후 : 332개
- ③ 회귀분석 후 모형 성능 평가 결과 : MSE (3.206), R2 score(0.951)

추정된 회귀방정식


$$Y = 60.340 + (0.510X_{rs7554978}) + \dots + (-0.668X_{rs1543031}) + (-0.542X_{rs2687683})$$

|            | coefficient |
|------------|-------------|
| intercept  | 60.340268   |
| rs7554987  | 0.510278    |
| rs2576320  | 0.480372    |
| rs11788069 | 0.479903    |
| rs10837204 | 0.450454    |
| ...        | ...         |
| rs2829979  | -0.419105   |
| rs8086878  | -0.464128   |
| rs2019203  | -0.473590   |
| rs2687683  | -0.542520   |
| rs1543031  | -0.668503   |

333 rows x 1 columns

변이가 나타남에 따라  
나이를 증가시키는  
변이 ID: 총 126개

변이가 나타남에 따라  
나이를 감소시키는  
변이 ID: 총 206개



<회귀식 적합도>

# 04. 모델링

## 4-1. 선형 회귀 분석 - Age


- Linear Regression

- ① Best top k 변이ID 개수 : 377개
- ② 상관분석 후 상관계수 높은 변이ID 제거 후 : 332개
- ③ 회귀분석 후 모형 성능 평가 결과 : MSE (3.206), R2 score(0.951)

추정된 회귀방정식

$$Y = 60.340 + (0.510X_{rs7554978}) + \dots + (-0.668X_{rs1543031}) + (-0.542X_{rs2687683})$$

- Coefficient 절대값이 모두 1미만
- 유의미한 변이 ID개수가 300개 이상으로 많음에 따라 뚜렷하게 영향력이 큰 변이ID는 없음



# 04. 회귀 분석

## 4-2. 로지스틱 회귀 분석 - Gender

- Logistic Regression

- ① Best top k 변이ID 개수 : 55개
- ② 상관분석 후 상관계수 높은 변이ID 제거 후 : 52개
- ③ 회귀분석 후 모형 성능 평가 결과 :  $\text{accuracy}(1.0)$ ,  $\text{f1-score}(1.0)$

추정된 회귀방정식

$$\text{logit}(P(y=1)) = -0.852 + \log(2.176X_{rs1038304}) + \log(2.018X_{rs35982506}) + \dots + \log(0.516X_{rs11185131})$$


해당 변이가 1 증가할 때, 남자로 분류할 확률 2.176배

|            | oddsratio |
|------------|-----------|
| rs10838304 | 2.176     |
| rs35982506 | 2.018     |
| rs2370113  | 1.872     |
| rs9804735  | 1.792     |
| rs2737141  | 1.753     |
| ...        | ...       |
| rs72721702 | 0.586     |
| rs905123   | 0.534     |
| rs1916463  | 0.518     |
| rs11185131 | 0.516     |
| intercept  | -0.852    |

53 rows x 1 columns

변이가 나타남에 따라  
남자일 확률을  
증가시키는  
변이 ID: 총 29개

변이가 나타남에 따라  
남자일 확률을  
감소시키는  
변이 ID: 총 23개



<ROC curve>

# 04. 회귀 분석

## 4-2. 로지스틱 회귀 분석 - Gender

- Logistic Regression


- ① Best top k 변이ID 개수 : 55개
- ② 상관분석 후 상관계수 높은 변이ID 제거 후 : 52개
- ③ 회귀분석 후 모형 성능 평가 결과 : accuracy(1.0), f1-score(1.0)

추정된 회귀방정식

$$\text{logit}(P(y=1)) = -0.852 + \log(2.176X_{rs1038304}) + \log(2.018X_{rs35982506}) + \dots + \log(0.516X_{rs17761583})$$

해당 변이가 1 증가할 때, 남자로 분류할 확률 2.176배

- odds ratio 값이 1.5 이상
- 해당 변이가 나타남에 따라 "남자"로 분류할 영향력이 1.5배 이상



<ROC curve>

# 04. 회귀 분석

## 4-3. 로지스틱 회귀 분석 - Ethnicity

### • Logistic Regression


- ① Best top k 변이ID 개수 : 14개
- ② 상관 분석 후 상관계수 높은 변이ID 제거 후 : 14개
- ③ 회귀 분석 후 모형 성능 평가 결과 : accuracy(1.0), f1-score(1.0)

#### 추정된 회귀방정식

$$\text{logit}(P(y=0)) = -0.2907 + \log(0.365X_{\text{Affx\_27417025}}) + \log(0.425X_{rs1258066}) + \dots + \log(0.357X_{rs78193725})$$

$$\text{logit}(P(y=1)) = -1.251 + \log(0.964X_{\text{Affx\_27417025}}) + \log(1.455X_{rs1258066}) + \dots + \log(4.032X_{rs78193725})$$

$$\text{logit}(P(y=2)) = -1.657 + \log(2.842X_{\text{Affx\_27417025}}) + \log(1.745X_{rs11553574}) + \dots + \log(1.725X_{rs12038310})$$



<ROC curve>

#### 0. British class

| ID | oddsratio_class0 |
|----|------------------|
| 0  | intercept        |
| 1  | rs16970979       |
| 2  | rs78963463       |
| 3  | rs62455736       |
| 4  | rs6873782        |
| 5  | rs79999510       |
| 6  | rs10774751       |
| 7  | rs7142070        |
| 8  | rs12038310       |
| 9  | rs72824058       |
| 10 | rs11553574       |
| 11 | rs4730125        |
| 12 | rs1258066        |
| 13 | Affx-27417025    |
| 14 | rs78193725       |

변이가 나타남에 따라  
british일 확률을  
감소시키는  
변이 ID: 총 12개

#### 1. Indian class

| ID | oddsratio_class1 |
|----|------------------|
| 0  | rs78193725       |
| 1  | rs1258066        |
| 2  | rs7142070        |
| 3  | rs4730125        |
| 4  | rs62455736       |
| 5  | rs72824058       |
| 6  | rs6873782        |
| 7  | rs16970979       |
| 8  | rs78963463       |
| 9  | Affx-27417025    |
| 10 | rs79999510       |
| 11 | rs11553574       |
| 12 | rs12038310       |
| 13 | rs10774751       |
| 14 | intercept        |

변이가 나타남에 따라  
Indian일 확률을  
증가시키는  
변이 ID: 총 7개

변이가 나타남에 따라  
Indian일 확률을  
감소시키는  
변이 ID: 총 5개

#### 2. African class

| ID | oddsratio_class2 |
|----|------------------|
| 0  | Affx-27417025    |
| 1  | rs11553574       |
| 2  | rs12038310       |
| 3  | rs1258066        |
| 4  | rs72824058       |
| 5  | rs4730125        |
| 6  | rs10774751       |
| 7  | rs79999510       |
| 8  | rs7142070        |
| 9  | rs6873782        |
| 10 | rs16970979       |
| 11 | rs78963463       |
| 12 | rs62455736       |
| 13 | rs78193725       |
| 14 | intercept        |

변이가 나타남에 따라  
African일 확률을  
증가시키는  
변이 ID: 총 10개

변이가 나타남에 따라  
African일 확률을  
감소시키는  
변이 ID: 총 2개

# 04. 회귀 분석

## 4-3. 로지스틱 회귀 분석

### • Logistic Regression


- ① Best top k 변이ID
- ② 상관 분석 후 상관계수
- ③ 회귀 분석 후 모형 상

추정된 회귀방정식

$$\text{logit}(P(y=0)) = -0.2$$

$$\text{logit}(P(y=1)) = -1.2$$

$$\text{logit}(P(y=2)) = -1.6$$



#### British group class

- odds ratio 값이 **모두 1 이하**
- 즉, 해당 변이가 일어나지 않아야 British group일 확률 증가

#### Indian group class

- odds ratio 값이 4 이상
- 해당 변이가 Indian group일 확률을 크게 증가시켜줌

#### African group class

- odds ratio 값이 약 3
- 해당 변이가 African group일 확률을 크게 증가시켜줌

## 모델링

5-1. 분석 개요

5-2. 회귀 모형

5-3. 분류 모형

5-4. 이상치 탐지 모형

5-5. 모델 결과 해석


## 5-1. 분석 개요

## 목표

- 머신러닝 모델은 복잡한 상호관계 포착, 과적합 방지 기법 등을 통해 일반적으로 회귀모형보다 높은 성능을 제공함
- 다양한 알고리즘을 기반으로 한 머신러닝 모델로 고도화된 예측 모델을 구축하고자 함
- 더 다양한 피쳐 구성 방법으로 성능이 뛰어난 모델을 구축


### <실험 환경>

- 데이터셋 구성 : 학습 데이터 80%, 평가 데이터 20%
- 학습 데이터에 적어도 해당 인종 1명 이상을 포함시킬 수 있도록 구성



# 05. 모델링


## 5-1. 분석 개요



|   | 피쳐 구성 방법론                     |
|---|-------------------------------|
| 1 | 변수 모두 사용                      |
| 2 | Correlation 기반 변수 제거          |
| 3 | PCA 수행                        |
| 4 | Correlation 기반 변수 제거 및 PCA 수행 |

# 05. 모델링

## 5-1. 분석 개요



\*정상이 아닌 이상치 데이터로 정의하고, 학습에 사용하지 않는 방법

### 1. ML 기반 분류 및 회귀 모형

- 3가지 label 예측을 위한 모델

|   | 분류 모형                   | 회귀모형                   |
|---|-------------------------|------------------------|
| 1 | Logistic Regressor      | Linear Regressor       |
| 2 | NaiveBayes Classifier   | Lasso                  |
| 3 | KNN Classifier          | Ridge                  |
| 4 | DecisionTree Classifier | DecisionTree Regressor |
| 5 | RandomForest Classifier | RandomForest Regressor |
| 6 | LGBM Classifier         | LGBM Regressor         |
| 7 | SVC                     | SVR                    |

### 2. ML 기반 이상치 탐지 모형

- 기 분석에서 제외되었던 **소수 인종 클래스(샘플이 1개)** 예측을 위한 모형 (Chinese, Any\_other\_mixed\_background)

|   | 이상치 탐지 모형 (인종 소수클래스 분류) |
|---|-------------------------|
| 1 | Isolation Forest        |
| 2 | OneClass SVM            |
| 3 | SGDOneClass SVM         |
| 4 | Local Outlier Factor    |

✓ 학습 데이터에는 예측하고자 하는 소수인종을 제외한 모든 인종이 포함됨.  
평가 시에 타 클래스 2명 포함하여 평가 시도

# 05. 모델링

## 5-2. 회귀 모형 - Age

- 일반적으로 대부분의 모델에서 PCA 혹은 PCA와 Correlation 방법 모두를 사용해서 예측하는 것이 가장 좋은 성능을 냄
- 사용된 피쳐 수는 320~330개 사이

가장 적은 피쳐를 사용해서 최고 성능을 보이는 모델과 방법론 :  
\*Linear Regression & Correlation 제거

### 모델 학습 및 예측 결과

| 회귀모형                   | Method            | feature 개수 | MSE   | R2   |
|------------------------|-------------------|------------|-------|------|
| Linear Regressor       | None              | 375        | 3.79  | 0.94 |
|                        | Correlation       | 326        | 3.28  | 0.95 |
|                        | PCA & Correlation | 330        | 5.37  | 0.92 |
|                        | PCA               | 395        | 6.69  | 0.9  |
| Lasso                  | None              | 235        | 12.25 | 0.81 |
|                        | Correlation       | 326        | 11.28 | 0.83 |
|                        | PCA & Correlation | 330        | 5.54  | 0.92 |
|                        | PCA               | 395        | 6.87  | 0.9  |
| Ridge                  | None              | 375        | 3.86  | 0.94 |
|                        | Correlation       | 326        | 3.4   | 0.95 |
|                        | PCA & Correlation | 330        | 5.37  | 0.92 |
|                        | PCA               | 395        | 6.69  | 0.9  |
| DecisionTree Regressor | None              | 30         | 32.74 | 0.5  |
|                        | Correlation       | 36         | 27.21 | 0.59 |
|                        | PCA & Correlation | 286        | 8.6   | 0.87 |
|                        | PCA               | 360        | 10.48 | 0.84 |
| RandomForest Regressor | None              | 45         | 18.69 | 0.72 |
|                        | Correlation       | 46         | 17.7  | 0.73 |
|                        | PCA & Correlation | 314        | 6.87  | 0.9  |
|                        | PCA               | 360        | 6.09  | 0.91 |
| LGBM Regressor         | None              | 340        | 15.53 | 0.76 |
|                        | Correlation       | 300        | 13.67 | 0.79 |
|                        | PCA & Correlation | 281        | 10.09 | 0.85 |
|                        | PCA               | 380        | 12.72 | 0.81 |
| SVR                    | None              | 370        | 3.84  | 0.94 |
|                        | Correlation       | 330        | 3.38  | 0.95 |
|                        | PCA & Correlation | 305        | 6.77  | 0.9  |
|                        | PCA               | 370        | 7.93  | 0.88 |


# 05. 모델링

## 4-2. 분류 모형 - Gender

- 일반적으로 대부분의 모델에서 PCA와 Correlation 방법 모두를 사용해서 예측하는 것이 가장 좋은 성능을 냄
- 사용된 피쳐 수는 9~14개 사이

가장 적은 피쳐를 사용해서 최고 성능을 보이는 모델과 방법론 :

**\*RandomForest Classifier & Correlation제거**



### 모델 학습 및 예측 결과

| 회귀모형                             | Method            | feature 개수 | Accuracy | F1-score |
|----------------------------------|-------------------|------------|----------|----------|
| Logistic Regressor               | None              | 46         | 1        | 1        |
|                                  | Correlation       | 27         | 1        | 1        |
|                                  | PCA & Correlation | 14         | 1        | 1        |
|                                  | PCA               | 23         | 1        | 1        |
| NaiveBayes Classifier            | None              | 56         | 0.9      | 0.9      |
|                                  | Correlation       | 53         | 0.9      | 0.9      |
|                                  | PCA & Correlation | 13         | 1        | 1        |
|                                  | PCA               | 28         | 1        | 1        |
| KNN Classifier                   | None              | 45         | 1        | 1        |
|                                  | Correlation       | 47         | 1        | 1        |
|                                  | PCA & Correlation | 13         | 1        | 1        |
|                                  | PCA               | 25         | 1        | 1        |
| DecisionTree Classifier          | None              | 6          | 0.9      | 0.9      |
|                                  | Correlation       | 4          | 0.9      | 0.9      |
|                                  | PCA & Correlation | 12         | 1        | 1        |
|                                  | PCA               | 35         | 1        | 1        |
| *best<br>RandomForest Classifier | None              | 27         | 1        | 1        |
|                                  | Correlation       | 9          | 1        | 1        |
|                                  | PCA & Correlation | 11         | 1        | 1        |
|                                  | PCA               | 26         | 1        | 1        |
| LGBM Classifier                  | None              | 15         | 0.95     | 0.95     |
|                                  | Correlation       | 14         | 0.95     | 0.95     |
|                                  | PCA & Correlation | 9          | 1        | 1        |
|                                  | PCA               | 9          | 1        | 1        |
| SVC                              | None              | 55         | 1        | 1        |
|                                  | Correlation       | 52         | 1        | 1        |
|                                  | PCA & Correlation | 13         | 1        | 1        |
|                                  | PCA               | 22         | 1        | 1        |


# 05. 모델링

## 5-3. 분류 모형 - Ethnicity

- 일반적으로 대부분의 모델에서 PCA와 Correlation 방법 모두를 사용해서 예측하는 것이 가장 좋은 성능을 냄
- 사용된 피쳐 수는 9~14개 사이

가장 적은 피쳐를 사용해서 최고 성능을 보이는 모델과 방법론 :

**\*DecisionTree Classifier & 모든 피쳐 사용**





| 회귀모형                                    | Method            | feature 개수 | Accuracy | F1-score |
|-----------------------------------------|-------------------|------------|----------|----------|
| Logistic Regressor                      | None              | 14         | 1        | 1        |
|                                         | Correlation       | 14         | 1        | 1        |
|                                         | PCA & Correlation | 12         | 0.97     | 0.95     |
|                                         | PCA               | 12         | 0.97     | 0.95     |
| NaiveBayes Classifier                   | None              | 8          | 0.97     | 0.95     |
|                                         | Correlation       | 8          | 0.97     | 0.95     |
|                                         | PCA & Correlation | 47         | 1        | 1        |
|                                         | PCA               | 50         | 1        | 1        |
| KNN Classifier                          | None              | 10         | 0.97     | 0.95     |
|                                         | Correlation       | 10         | 0.97     | 0.95     |
|                                         | PCA & Correlation | 43         | 1        | 1        |
|                                         | PCA               | 46         | 1        | 1        |
| <b>*best</b><br>DecisionTree Classifier | None              | 8          | 1        | 1        |
|                                         | Correlation       | 10         | 1        | 1        |
|                                         | PCA & Correlation | 18         | 1        | 1        |
|                                         | PCA               | 14         | 1        | 1        |
| RandomForest Classifier                 | None              | 12         | 1        | 1        |
|                                         | Correlation       | 12         | 1        | 1        |
|                                         | PCA & Correlation | 10         | 1        | 1        |
|                                         | PCA               | 10         | 1        | 1        |
| LGBM Classifier                         | None              | 2          | 0.86     | 0.8      |
|                                         | Correlation       | 2          | 0.86     | 0.8      |
|                                         | PCA & Correlation | 47         | 1        | 1        |
|                                         | PCA               | 46         | 1        | 1        |
| SVC                                     | None              | 56         | 1        | 1        |
|                                         | Correlation       | 52         | 1        | 1        |
|                                         | PCA & Correlation | 16         | 0.97     | 0.95     |
|                                         | PCA               | 16         | 0.97     | 0.95     |

# 05. 모델링

## 5-4. 이상치 탐지 모형 - Ethnicity



모델 학습 및 예측 결과 : Chinese

| 이상치 탐지 모형<br>(Chinese class) | Method            | feature 개수 | Accuracy | F1   |
|------------------------------|-------------------|------------|----------|------|
| Isolation Forest             | None              | 2          | 0.67     | 0.53 |
|                              | Correlation       | 2          | 0.67     | 0.53 |
|                              | PCA & Correlation | 2          | 1        | 1    |
|                              | PCA               | 2          | 1        | 1    |
| OneClass SVM                 | None              | 2          | 0.67     | 0.53 |
|                              | Correlation       | 2          | 0.67     | 0.53 |
|                              | PCA & Correlation | 2          | 1        | 1    |
|                              | PCA               | 2          | 1        | 1    |
| SGDOneClass SVM              | None              | 2          | 0.33     | 0.17 |
|                              | Correlation       | 2          | 0.33     | 0.17 |
|                              | PCA & Correlation | 2          | 1        | 1    |
|                              | PCA               | 2          | 1        | 1    |
| Local Outlier Factor         | None              | 2          | 0.67     | 0.53 |
|                              | Correlation       | 2          | 0.67     | 0.53 |
|                              | PCA & Correlation | 6          | 1        | 1    |
|                              | PCA               | 4          | 1        | 1    |



모델 학습 및 예측 결과 : Any other mixed background

| 이상치 탐지 모형<br>(Any_other_mixed_background class) | Method            | feature 개수 | Accuracy | F1   |
|-------------------------------------------------|-------------------|------------|----------|------|
| Isolation Forest                                | None              | 2          | 0.5      | 0.33 |
|                                                 | Correlation       | 2          | 0.5      | 0.33 |
|                                                 | PCA & Correlation | 2          | 0.5      | 0.33 |
|                                                 | PCA               | 2          | 0.5      | 0.33 |
| OneClass SVM                                    | None              | 2          | 0.5      | 0.33 |
|                                                 | Correlation       | 2          | 0.5      | 0.33 |
|                                                 | PCA & Correlation | 2          | 0.5      | 0.33 |
|                                                 | PCA               | 2          | 0.5      | 0.33 |
| SGDOneClass SVM                                 | None              | 2          | 0.5      | 0.33 |
|                                                 | Correlation       | 2          | 0.5      | 0.33 |
|                                                 | PCA & Correlation | 27         | 1        | 1    |
|                                                 | PCA               | 20         | 1        | 1    |
| Local Outlier Factor                            | None              | 2          | 0.5      | 0.33 |
|                                                 | Correlation       | 2          | 0.5      | 0.33 |
|                                                 | PCA & Correlation | 2          | 0.5      | 0.33 |
|                                                 | PCA               | 2          | 0.5      | 0.33 |



- 이상치 탐지 모델링을 통해 sample이 1개 뿐이었던 Chinese class 와 Any other Mixed background class를 분류해 냄
- 하지만, 샘플이 하나 뿐인 결과이기 때문에 여전히 신뢰성을 입증하기 어려움


# 05. 모델링

## 5-5. 모델 결과 해석 - LIME

### LIME 이란?


- LIME(Locally Interpretable Model-agnostic Explanations)은 모델이 왜 특정한 예측을 했는지, 어떤 특징이 그 예측에 얼마나 기여했는지를 해석하기 위해 사용되는 기법.
- LIME은 특정한 예측 (샘플)에 대해 로컬(local) 해석을 제공하며, 모델에 종속되지 않는 model-agnostic 특성이 있음.

Sample prediction <Age>



| Feature    | Value |
|------------|-------|
| rs1543031  | 0.00  |
| rs2019203  | 0.00  |
| rs2687683  | 0.00  |
| rs10837204 | 0.00  |
| rs10426528 | 0.00  |
| rs35511327 | 2.00  |
| rs250834   | 2.00  |
| rs4675212  | 0.00  |

Sample prediction <Gender>




| Feature    | Value |
|------------|-------|
| rs35982506 | 2.00  |
| rs6733379  | 2.00  |
| rs905123   | 2.00  |
| rs10838304 | 0.00  |
| rs11185131 | 0.00  |
| rs2737141  | 0.00  |
| rs1916463  | 0.00  |
| rs705708   | 0.00  |

# 05. 모델링


## 5-5. 모델 결과 해석 - LIME

Sample prediction <British Class>





| Feature       | Value |
|---------------|-------|
| rs78193725    | 0.00  |
| Affx-27417025 | 0.00  |
| rs7142070     | 0.00  |
| rs1258066     | 0.00  |
| rs4730125     | 0.00  |
| rs12038310    | 0.00  |
| rs72824058    | 0.00  |
| rs6873782     | 0.00  |

Sample prediction <African Class>



| Feature       | Value |
|---------------|-------|
| Affx-27417025 | 2.00  |
| rs7142070     | 1.00  |
| rs4730125     | 1.00  |
| rs10774751    | 0.00  |
| rs72824058    | 0.00  |
| rs12038310    | 1.00  |
| rs1258066     | 1.00  |
| rs6873782     | 0.00  |

Sample prediction <Indian Class>



| Feature       | Value |
|---------------|-------|
| rs78193725    | 1.00  |
| rs1258066     | 0.00  |
| rs7142070     | 0.00  |
| Affx-27417025 | 2.00  |
| rs72824058    | 0.00  |
| rs62455736    | 0.00  |
| rs79999510    | 0.00  |
| rs6873782     | 0.00  |

# 05. 모델링

## 5-5. 모델 결과 해석 - LIME


Sample prediction <British Class>

Prediction probabilities

|               |      |
|---------------|------|
| British Class | 1.00 |
| Indian Class  | 0.00 |
| African Class | 0.00 |

NOT British Class

rs78193725 > 0.00  
Affx-27417025 > 0.00  
rs7142070 > 0.00  
rs1258066 <= 0.00  
rs4730125 <= 0.00  
rs12038310 <= 0.00  
rs72824058 <= 0.00  
rs6873782 <= 0.00



Ethnicity

- British\_class
- African\_class
- Indian\_class

Sample prediction <African Class>

Prediction probabilities

|               |      |
|---------------|------|
| British Class | 0.02 |
| Indian Class  | 0.02 |
| African Class | 0.96 |

NOT African Class

African Class

rs10774751 <= 0.00  
rs72824058 <= 0.00  
rs12038310 > 0.00  
rs1258066 > 0.00  
rs6873782 <= 0.00  
Affx-27417025 > 0.00  
rs7142070 > 0.00  
rs4730125 > 0.00

Feature Value

|               |      |
|---------------|------|
| Affx-27417025 | 2.00 |
| rs7142070     | 1.00 |
| rs4730125     | 1.00 |
| rs10774751    | 0.00 |
| rs72824058    | 0.00 |
| rs12038310    | 1.00 |
| rs1258066     | 1.00 |
| rs6873782     | 0.00 |

Indian과 타 인종간의 유사성이 있는 것으로 보임

Sample prediction <Indian Class>

Prediction probabilities

|               |      |
|---------------|------|
| British Class | 0.26 |
| Indian Class  | 0.50 |
| African Class | 0.24 |

NOT Indian Class

Indian Class

rs78193725 > 0.00  
rs1258066 <= 0.00  
rs7142070 <= 0.00  
rs72824058 <= 0.00  
rs62455736 <= 0.00  
rs79999510 <= 0.00  
rs6873782 <= 0.00  
Affx-27417025 > 0.00

NOT British Class

British Class

Affx-27417025 > 0.00  
rs1258066 <= 0.00  
rs78193725 > 0.00  
rs12038310 <= 0.00  
rs7142070 <= 0.00  
rs72824058 <= 0.00  
rs79999510 <= 0.00  
rs62455736 <= 0.00

Feature Value

|               |      |
|---------------|------|
| rs78193725    | 1.00 |
| rs1258066     | 0.00 |
| rs7142070     | 0.00 |
| Affx-27417025 | 2.00 |
| rs72824058    | 0.00 |
| rs62455736    | 0.00 |
| rs79999510    | 0.00 |
| rs6873782     | 0.00 |

## 추가 분석

### 6-1. 변이 유형 분석

# 06. 결과 분석

## 6-1. 변이 유형 분석

### Variant Type

#### 유전적 변이에 대한 유형

- ① SNPs : DNA 서열의 단일 염기가 다른 염기로 변형
- ② Insertion : DNA 서열에서 하나 이상의 염기 추가
- ③ Deletion : DNA 서열에서 하나 이상의 염기 삭제

| CHROM | POS    | ID            | REF   | ALT | VARIANT_TYPE |
|-------|--------|---------------|-------|-----|--------------|
| 1     | 787927 | rs28659788    | C     | G   | SNP          |
| 1     | 941118 | Affx-52325915 | G     | GA  | Insertion    |
| 1     | 939350 | Affx-89008640 | TGAGC | T   | Deletion     |

<age>

```
VARIANT_TYPE
SNP      331
Insertion 1
Name: count, dtype: int64
```

<gender>

```
VARIANT_TYPE
SNP      52
Name: count, dtype: int64
```


<ethnicity>

```
VARIANT_TYPE
SNP      4
Name: count, dtype: int64
```


# 06. 결과 분석

## 6-1. 변이 유형 분석 - Most Severe Consequence (Ensembl)


Age



Gender



Ethnicity




- Ensembl 데이터베이스를 통해 유의미한 변이들의 추가적인 정보를 수집함
- 전반적으로 Intron, intergenic 변이의 비율이 높음
- Missense를 제외한 변이들은 단백질 구조 혹은 기능에 큰 영향을 미치지 않는 것으로 판단됨
- **Missense 변이**는 단백질 기능을 상실하게 할 수 있으며, 질병의 원인으로 이어질 가능성이 있어 추가 연구가 필요함


# 06. 결과 분석

## 6-1. 변이 유형 분석 - Circos Plot


Age



Ethnicity



Gender



Circos plot으로 시각화를 하여 각 라벨별 유의미한 변이들이 분포된 염색체와 염색체 상의 위치를 확인함

## 결론

7-1. 결론 및 한계점

7-2. 제언

# 07. 결론

## 7-1. 결론 및 한계점

### 결론

- ① GWAS를 통해 3가지 라벨별 **유의미한 feature**를 추출함
- ② 유의미한 feature 조합으로 모형 적합도가 높은 **회귀식을 도출**함
- ③ 합리적인 방법론을 통해 최소한의 feature 조합으로 각 라벨 예측 성능이 **우수한 AI 모델을 구축**함
- ④ **각 변이들이 나이, 인종, 성별에 미치는 영향을 체계적으로 분석**함

### 한계점

- 절대적인 **샘플 수 부족**으로 분석 결과를 일반화 하기 어려움
- 특히 인종의 경우, **인종 class 별로 불균형이 매우 심각**하여 소수 class에 대해 더 많은 샘플이 필요함
- 목표로 하는 맞춤형 치료 서비스를 제공하기에는 3종류의 라벨로는 어려움이 있음

# 07. 결론

## 7-2. 제언

Age, eth, gender <- 기본적인 개인식별임.  
이를 넘어서 완전한 개인식별이 가능하다면, Most  
severe Consequence와 관련지어서  
해당변이가 유발할 수 있는 질병에 대한 더 구체적인  
연구를 통해 사전에 질병을 예방할 수 있는 ~~

- 나이, 인종, 성별은 개인식별을 위한 가장 기초적인 정보이므로, 더 디테일한 개인 식별을 위해서는 추가적인 라벨 데이터가 필요함.
- 이와 같은 문제점을 해결하기 위해, 다음과 같은 추가 데이터 수집을 제안
- 추가 데이터를 활용한다면 고도화된 개인 식별 모델을 확립할 수 있을 것
- 이를 기반으로 더 발전된 개인 맞춤형 헬스케어 서비스 제공 가능

### 신체적 특징

키, 몸무게, 탈모,  
머리색, 피부색 등

### 식생활 습관

음주 횟수, 흡연 여부,  
불면 여부 등

### 성향


충동성, 공격성 등

### 건강기록

병력, 진료 기록,  
약물복용 기록 등

# 07. 결론

## 7-2. 제언



### 개인 식별

- 앞서 구축한 모델로 **고도화된 개인 식별**
- 유전체 데이터 분석을 통해 **다양한 특성\*에 영향을 미치는 변이 분석**  
\* 특정 질병 감수성, 생리적 특성, 행동적 특성

### 솔루션 제공

- **개인의 건강 상태에 최적화된 맞춤형 솔루션** 제공
  - 특정 질병 위험이 높은 개인을 위한 예방 전략 및 관리 제공
  - 개인의 영양 요구와 특성에 맞춘 맞춤형 식단 설계 등

### 지속적 관리

- 정기적인 유전체 모니터링 시행
- 맞춤형 건강 플랜 업데이트