



대규모 언어 모델 기반 암 치료 반응 분류 모델 개발

하재훈

Contents.

01 분석 배경

02 전처리 및 데이터 탐색

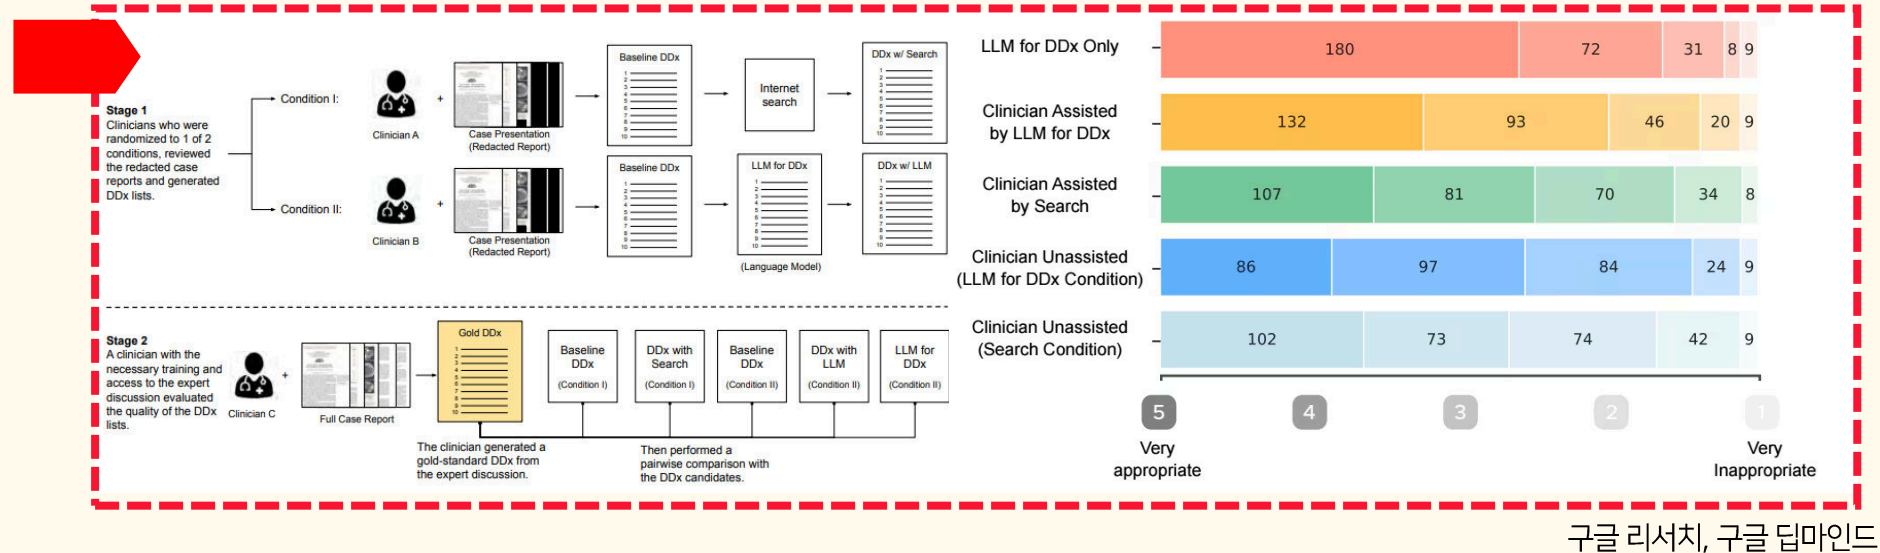
03 LLM 모델 학습

04 최종 모델 소개

05 XAI를 통한 토큰 분석

06 결론 및 제언

01 분석 배경

Towards Accurate Differential Diagnosis with Large Language Models¹⁾

구글 헬스 AI팀은 지난 11월 30일 논문 사전공개 사이트인 '아카이브(arXiv)'에 대규모 언어 모델(LLM)을 활용한 AI가 질환을 얼마나 정확하게 진단할 수 있는지 보여주는 논문을 제시하였다.

해당 연구에 따르면, AI 혼자 진단한 경우 59.1%의 정확도, 임상이가 혼자 진단한 경우 33.6%, 임상이가 AI의 도움을 받은 경우 51.8%, 임상이가 인터넷 검색을 활용하여 진단한 경우 44.5%의 진단 정확도를 보였다.

“논문의 연구팀은 이번 연구 결과가 의료 현장에서 임상가의 대신 AI를 써야 하는 것을 의미하는 것이 아니라, 오히려 복잡한 진단 과정에서 AI가 임상가를 돕는 보조 역할을 하는 방법을 찾는게 중요하다고 강조하였다”

1) McDuff, D., Schaekermann, M., Tu, T., Palepu, A., Wang, A., Garrison, J., ... & Natarajan, V. (2023). Towards accurate differential diagnosis with large language models. *arXiv preprint arXiv:2312.00164*.

암 분류 작업의 필요성

연세대학교 의과대학 의생명시스템정보학교실 김휘영 교수 인터뷰

"생성형 AI는 수준 높은 해석과 이해를 요구하는 의학적 지식을 쉽게 이해할 수 있는 형태로 풀어낸다.
일반인은 물론 저연차 전공의나 의대생도 평가하기 어려운 임상 내용을 분석해
진료나 연구에 바로 쓸 수 있도록 '초벌 작업'을 수행하는 것도 가능하다"

연세의대 의생명시스템정보학교실 김휘영 교수
출처 : 청년의사(<http://www.docdocdoc.co.kr>)



02

전처리 및 데이터 탐색

	Reports	GT_label
0	Clinical information: Medulloblastoma \n\nWhole-spine MRI with contrast enhancement. \n\nNo evidence of leptomeningeal seeding metastasis.\nNormal conus medullaris end level, without syringomyelia. \nNo significant filum terminale thickening. \nNo abnormal signal intensity in axial skeleton or spinal cord. \n\nImpression: No evidence of leptomeningeal seeding metastasis.	no
1	EXAM: Whole spine MRI with contrast enhancement\n\nCLINICAL INFORMATION: Lung cancer (adenosquamous carcinoma) \n\nFINDINGS:\nBone marrow replacing lesions with contrast enhancement involving T4, clinically known metastasis.\nSymmetric disc bulging in L4/5 and L5/S1. \nPerineural cyst in S2 level. \n\nIMPRESSION:\n1. Known metastasis at T4 vertebral body.\n2. Perineural cyst in S2 level. \n\nRECOMMENDATION: Clinical correlation.	mets
2	EXAM : Whole spine enhanced MRI with tumor protocol. \n\nCLINICAL INFORMATION : Advanced gastric cancer with bone and leptomeningeal metastasis, on palliative CTx. \n\nCOMPARISON : 2020-12-22 MRI. \n\nFINDINGS : \n\nNodular thickening of leptomeninges with contrast enhancement along spinal cord, from cranial meninges within scanned range to cauda equina.\n - Increased extent compared with previous study. \n - Suspected cord compression at the level of L1, with diffuse cord swelling with T2 signal change and enhancement at T12-L1 level.\n\nNo change of poor visualization of multiple marrow replacing lesions in the C, T, L, S- spines, sternum, ribs, and pelvic bone. \n\nCONCLUSION : \n\nProgression of leptomeningeal seeding.	progression
3	\n\nEXAM: Whole spine MRI with enhancement. \n\nClinical information: Lung cancer. \n\nFindings: \n\nNo abnormal bone marrow replacing or enhancing lesion in noted. \n\nUnremarkable finding of spinal cord. \n\nL2/3 and L3/4: Bulging disc with facet hypertrophy. \n\nL4/5: bulging disc and decreased height of disc with facet hypertrophy. \n\nMass in the right lower lobe of lung and pleural thickening. \n\nConclusion: \n\nNo evidence of bony metastasis. \n\nRecommendation: \n\nClinical correlation.	no
4	\n\nEXAM: Whole spine contrast enhanced MRI \n\nThe patient with history of renal cell carcinoma (RCC). \n\nComparison : 2022-02-27 \n\nFINDINGS: \n\nNo remarkable change of intradiscal fluid signal of T3/4 disc with adjacent bone destruction and enhancement on T3 and T4 bodies. \n\nNo other bone marrow replacing lesion or signal change of the spinal cord. \n\nDegenerative bony spur with disc bulging at C5/6 and C6/7 without significant spinal canal stenosis. \n\nIMPRESSION: \n\n1. Stable status of improved spondylodiscitis in T3/4 level. \n\n2. No evidence of bone metastasis. \n\nRecommendation: Clinical correlation.	stable
...	...	...
695	EXAM : Whole spine MRI with contrast enhancement. \n\nCLINICAL INFORMATION : Rectal cancer. \n\nFINDINGS : \n\nNo definite marrow replacing enhancing lesion to suggest bone metastasis. \n\nNo significant cord signal abnormality. \n\nBulging discs and thickening of ligamentum flavum in lumbar and cervical spine. \n\nRetrolisthesis, L5/S1. \n\nLimbus vertebra, L3. \n\nMultiple Schmorl's nodes in thoracolumbar vertebrae. \n\nApproximately 9mm sized T2 hyperintense enhancing mass in dermal layer of posterior cervical area. \n\nCONCLUSION : \n\nNo evidence of spine metastasis. \n\nR/O Soft tissue lesion in posterior neck. \n\nRECOMMENDATION : Clinical correlation. \n\nFocused ultrasonography if clinically indicated.	no
696	Exam : Whole spine MR with contrast enhancement \n\nC.C. : Neck, low back pain, both leg paraesthesia \n\nHx : Lung cancer (stage IV, E19del) \n\nFindings \n\nNo abnormal enhancing lesion suggesting spine metastasis. \n\nNo significant central canal stenosis. \n\nNo definite focal lesion along spinal cord. \n\nImpression : \n\nNo evidence of bone metastasis. \n\nRecommendation: Clinical correlation.\n	no
697	\n\nExam: Whole-spine MRI with contrast enhancement. \n\nClinical information: Malignant melanoma. \n\nCompared with 2021-06-12 MRI. \n\nFindings: \n\nBone marrow replacing lesion with contrast enhancement at L4 posterior column and vertebral body. \n\nNo significant cord signal abnormalities. \n\nDisc bulging and degeneration with Modic change at L4/5 (Type 2). \n\nSmall enhancing lesion in C6 body, R/O hemangioma. \n- High signal intensity on T1 and T2WI. \n\nSchmorl's node at the lower endplate of T5 body. \n\nCONCLUSION : \n\nR/O Bone metastasis at L4 posterior column and vertebral body. \n\nRECOMMENDATION: Clinical correlation. \n	romets
698	Exam: Whole-spine MRI with contrast enhancement. \n\nClinical information: Cervix cancer, s/p spine Op (C3-T2), s/p RTx to C-spine and Lt scapula (2020). \n\nComparison: Unspecified T-L-spine MRI on 2021-03-21. \n\nFindings: \n\nPosterior spinal fusion state at C3-T2.\nGrade III compression fracture, bone marrow low signal intensity without contrast enhancement of C5 vertebra, probably post-treatment state.\nEnhancing posterior bulging mass lesion on the T2 body, abutting the spinal cord. No available prior image for comparison.\nIncreased extent of bone metastasis involving entire bone marrow of T11 and L3 vertebrae with extraosseus extensions.\nNewly developed pathologic compression fractures at T11 and L3 causing severe central canal stenosis. Cord compression at T11 level.\n\nConclusion: \n\n1. Progressive disease. \n - Increased bone metastases at T11 and L3 with pathologic compression fracture and extraosseus extensions.\n - Severe central canal stenosis at T11 and L3.\n2. Probably post-treatment state of C5.\n3. Bone metastasis at T2 with anterior epidural mass.	progression
699	EXAM: Whole spine MRI with contrast enhancement and DWI.\n\nClinical information: Prominent sclerotic lesion in T8 vertebra at chest CT, R/O metastasis.\n\nThe patient with a history of breast cancer.\n\nIn reference with 2023-5-15 Chest CT, 2022-11-10 CT, 2021-8-25 CT, and 2022-3-14 MRI.\n\nFINDINGS:\n\nFocal enhancing lesions with mild perilesional enhancement and T2 hypointensity in the T8 vertebra and T7 vertebra.\n\nNo significant interval change in T8 lesion.\n\nRight foraminal protrusion, T7/8 with lateral canal narrowing.\n\nCONCLUSION:\n\nR/O lateral compression fracture in T8. DDx. Metastatic lesion, less likely.\n\nLateral canal narrowing, T7/8.\n\nRECOMMENDATION:\n\nClinical correlation and close follow-up (three-month).	romets

- **romets** (병이 있어 정밀검사 필요)
- **progression** (암이 진행됨)
- **improved** (암 치료 후 호전됨)
- **no** (암 부재 또는 처음부터 암이 없었음)
- **mets** (새로운 전이 발생)
- **stable** (치료 이후 암이 진행되지 않고 안정적)

- 'no', 'no ', 'No' 라벨을 'no'로 통일
- 모든 text를 소문자로 변경
 - Exam, EXAM, exam 등 똑같은 의미를 갖는 단어들이 각각의 대소문자로 구분됨을 방지
- NLTK의 stopwords 사전을 활용하여 불용어 제거
- 정규표현식을 사용하여 특수문자와 줄바꿈 (\n) 제거

처리 예시

Clinical information: Medulloblastoma

Whole-spine MRI with contrast enhancement.

No evidence of leptomeningeal seeding metastasis.

Normal conus medullaris end level, without syringomyelia.


No significant filum terminale thickening.

No abnormal signal intensity in axial skeleton or spinal cord.

Impression: No evidence of leptomeningeal seeding metastasis

clinical information medulloblastoma
 wholespine mri contrast enhancement
 no evidence of leptomeningeal seeding
 metastasis normal conus medullaris end level
 without syringomyelia no significant filum
 terminale thickening no abnormal signal
 intensity axial skeleton spinal cord impression
 no evidence of leptomeningeal seeding
 metastasis

- 텍스트 토큰 개수 확인 도구 : Bert Tokenizer로 각 Reports의 토큰 개수 확인
- 결과 : 대부분의 Reports는 300개 이하의 토큰
 - Max_length를 512 이상 학습할 경우, 100~200개의 토큰을 가지고 있는 reports는 과도한 Zero padding을 하게 되는 현상 발생
 - Attention mask를 사용하여 Padding에 주의를 기울이지 않도록 할 수 있으나, 여전히 Zero padding이 계산에 포함되어 모델의 능력에 제한이 있을 수 있음 ¹⁾ (Dai et al., 2020)
- 최종학습 : Max_length 300 사용(300 이상이면 300 단위로 잘라서 사용)
 - 493 토큰 data는 이상치로 처리, 300에 맞게 Summarization 후 사용함



count	700.00
mean	156.64
std	65.68
min	36.00
25%	108.00
50%	146.50
75%	190.25
max	493.00

• 모델 학습 전,
TF-IDF 기준 각
Label 별
키워드 확인

-exam, mri, bone,
clinical 등 모든 label
에서 자주 혼용되는
단어들은 제외하기 위
해 각 label별 겹치지
않는 unique한
키워드 추출



[illegible][illegible]


considered
fractures
much one
seeding
developed
dysarthria
radiation
arising
lesions
abutting
replaced
right left
nipple
lobulated
includes
severe
anterior
included
recommended
overall
two-typed
ligamentum
osteoepithes
induced
volving
fluid
stage
screw
clivus
two
rretlated
gefinitim
needed
multiple
radiotherapy
relatively
sag
another

[illegible]

03

LLM 모델 학습

데이터셋




실험 환경

서버	DA 23번
CPU	XEON#W-2135
RAM	16GB * 8
GPU	Galaxy GeForce RTX 3090 SG D6X
HDD	SSD 512GB * 1, HDD 4TB * 1


- Pre-trained LM/LLM 모델을 Fine-tuning하여 실험
- LoRA/QLoRA는 일부 파라미터를 저차원으로 재구성하여 모델의 특정 부분만을 효율적으로 학습
 - 모델을 양자화하여 필요한 메모리를 더욱 줄이면서 성능을 유지하고, 큰 모델을 적은 자원으로 효과적으로 학습
- Fine-tuning과 함께 5가지 방법론을 통해 성능 향상을 도모함

PEFT


Standard



LoRA



QLoRA



**5가지
추가 방법론**

- 텍스트 분류에 성능이 탁월한 BERT 기반의 언어 모형 4개를 각각 Fine-tuning하여 실험
- BERT, RoBERTa, ELECTRA, ALBERT

BERT	precision	recall	F1-score	accuracy
Improved	1.00	0.81	0.89	0.86
mets	0.80	1.00	0.89	
no	0.96	0.88	0.91	
progression	0.83	0.83	0.83	
romets	0.65	0.74	0.69	
stable	0.85	0.85	0.85	

ELECTRA	precision	recall	F1-score	accuracy
Improved	0.93	0.93	0.93	0.90
mets	0.90	0.97	0.94	
no	0.96	0.93	0.95	
progression	1.00	0.88	0.94	
romets	0.81	0.91	0.86	
stable	0.93	0.90	0.91	

RoBERTa	precision	recall	F1-score	accuracy
Improved	0.93	0.93	0.93	0.90
mets	0.88	1.00	0.93	
no	0.93	0.93	0.93	
progression	0.97	0.85	0.91	
romets	0.81	0.81	0.81	
stable	0.93	0.90	0.91	

ALBERT	precision	recall	F1-score	accuracy
Improved	0.82	0.93	0.87	0.84
mets	0.89	0.85	0.87	
no	0.85	0.87	0.86	
progression	0.93	0.93	0.93	
romets	0.72	0.69	0.71	
stable	0.79	0.75	0.77	

- 3개의 open-source LLM을 Fine-tuning하여 실험
- LLaMA3-8B, Gemma-7B, Mistral-7B-v0.3

LLaMA3 (8B)	precision	recall	F1-score	accuracy
Improved	0.89	0.89	0.89	0.88
mets	0.88	0.88	0.88	
no	0.88	0.88	0.88	
progression	0.84	0.94	0.89	
romets	0.72	0.76	0.74	
stable	1.00	0.90	0.95	

Gemma (7B)	precision	recall	F1-score	accuracy
Improved	1.00	0.83	0.91	0.87
mets	0.94	0.85	0.89	
no	0.79	0.93	0.86	
progression	0.88	0.93	0.90	
romets	0.81	0.65	0.72	
stable	0.84	0.93	0.88	

Mistral (7B)	precision	recall	F1-score	accuracy
Improved	0.88	1.00	0.94	0.86
mets	0.85	0.85	0.85	
no	0.87	0.76	0.81	
progression	0.86	1.00	0.92	
romets	0.78	0.69	0.73	
stable	0.90	0.90	0.90	

- BERT 기반의 모델과 LLM 모두 성능이 괜찮음
- 하지만 전반적으로 'Romets' 라벨 분류 성능이 저조한 것을 확인함
- 이를 개선하고 전반적인 성능을 향상시키고자 5가지 실험을 진행
 1. 역번역
 2. 동의어 대체
 3. Paraphrase
 4. romets v.s other 이진 분류
 5. Prompt Engineering

1 역번역

- 임의의 15개의 'romets' 데이터를 한글로 번역 후 다시 영어로 재번역
 - 번역 모델은 'squarelike/Gugugo-koen-1.3B-V1.0' 사용
- 15개의 romets 데이터를 증강시킨 후 Llama3 모델에 재학습
 - romet's f1 : 0.78, accuracy: 0.79
 - 재번역을 통한 romets 증강은 성능에 큰 영향을 미치지 않음

2 동의어 대체

- 'romets' 데이터 중 임의의 5~10개의 단어를 동의어로 대체
 - nltk의 wordnet 사용
- 10~30개의 romets 데이터를 증강시킨 후 Llama3 모델에 재학습
 - romet's f1 : 0.83, accuracy: 0.84
 - 동의어를 사용하여 약간의 romets 성능을 향상시킴

3 Paraphrase

- 'Reports'를 300 토큰에 맞게 paraphrasing

- Gemma 2b, 구글 Pegasus-xsum 사용

- 최종 max_length인 300에 맞게 모든 reports의 토큰 숫자를 300으로 맞춰 모델을 학습

- 300 토큰 이하인 데이터들은 300에 맞춰 토큰을 늘림
- 300 토큰 이상인 데이터들도 300에 맞춰 요약
- 오히려 성능이 약 5% 정도 저하됨

4 이진 분류

- romets & others로 이진 분류 학습

- 먼저 romets와 others로 이진 분류를 하고, 그 다음 나머지 5개 라벨을 예측하는 방식
- 2가지의 모델을 사용: romets와 others를 예측하는 모델, 그리고 나머지를 예측하는 모델

- 나머지를 예측하는 모델은 전체적으로 성능이 우수했으나, 이진 분류 모델의 romets 성능이 나아지지 않음

- Binary model romet's f1: 0.72
- 5 classes model f1: 0.91

5 Prompt Engineering

- 미세조정된 LLaMA 3 모델로 zero-shot prompt engineering 시도하였으나, 할루시네이션이 심한 답을 생성

You are an oncology specialist. Classify this text into improved, no, romets, mets, progression, or stable and describe why you choose that answer.

The dataset contains 1100 radiology reports written by radiologists in Chinese and English and their corresponding classification labels. You are asked to build a model to predict the classification labels. Please use the following steps to implement the model. 1. Clean the dataset and split it into training, validation, and testing sets. 2. Build the model by using the following techniques.....

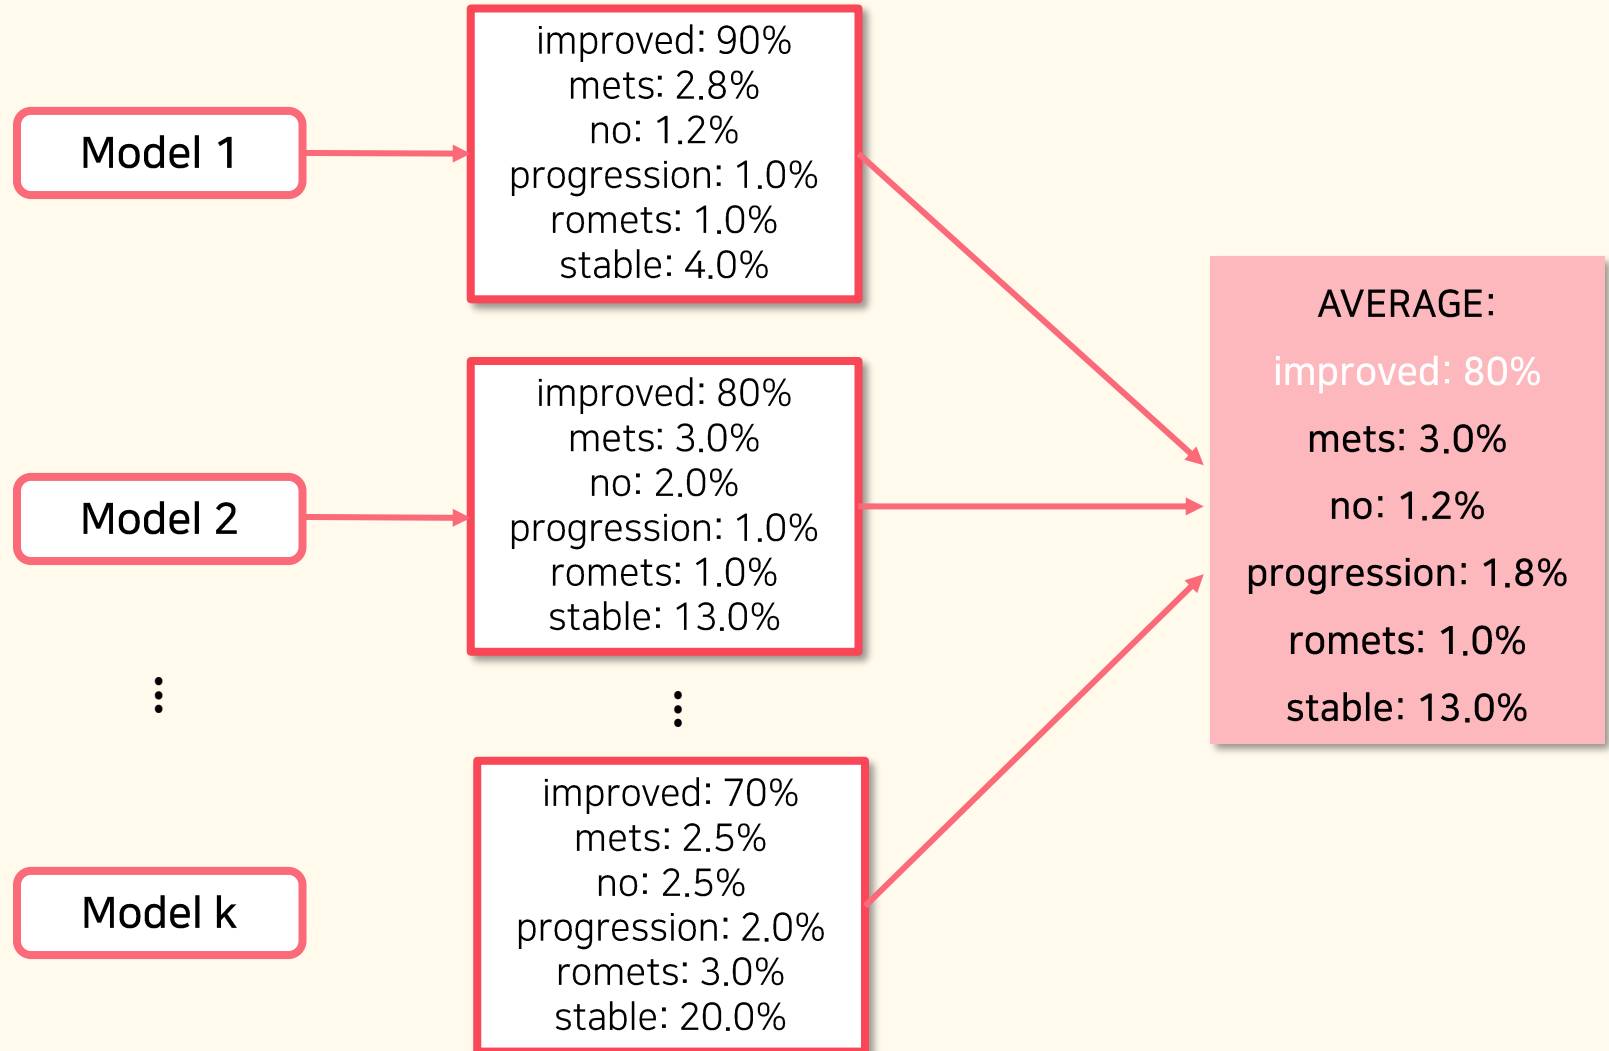
5가지 방법론 실험 결과, 'Romets' 클래스의 성능 개선 효과가 뚜렷하게 나타나지 않음.
이에 다음과 같은 마지막 학습 방법 시행

1. 하이퍼 파라미터 튜닝
2. 앙상블 방법
3. 의학용어로 사전학습된 모델 사용

Soft voting Ensemble

Models
biobert
Llama3.1
biogpt
roberta
biomist
biollama

모든 모델 조합에 대해 수행



BioBERT¹⁾

model_name = "biobert-v1.1"

- 모델: biobert
- 기반 모델: BERT
- 학습 데이터셋: BooksCorpus, English Wikipedia, PubMed Abstracts, PMC Full-text articles
- 성능: BioASQ, NCBI disease, BC2GM 등 다양한 biomedical tasks 에서 높은 성능을 보임
- 용도: 텍스트 분류, 감정분석, 질의응답
- 가중치: romets에 다른 클래스들 보다 3배 더 큰 손실(loss)를 부여

Parameter	Value
Batch size	6
Optimizer	AdamW
Learning rate	2e-5
Maximum sequence Length	300
Epochs	50

BioBERT	precision	recall	F1-score	accuracy
Improved	0.90	0.93	0.93	0.92
mets	0.95	0.95	0.95	
no	0.95	0.91	0.93	
progression	0.84	0.90	0.87	
romets	0.88	0.88	0.88	
stable	0.95	0.90	0.92	

1) Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., & Kang, J. (2020). BioBERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4), 1234-1240.

RoBERTa

model_name = "roberta-base"

- 모델: RoBERTa-Base
- 기반 모델: BERT
- 학습 데이터셋: BooksCorpus, English Wikipedia, CC-News, OpenWebText, Stories (160GB)
- 성능: GLUE, SQuAD, RACE에서 BERT, XLNet의 성능을 능가
- 용도: 텍스트 분류, 감정분석, 질의응답, 요약 등 NLP 태스크
- 가중치: romets에 다른 클래스들 보다 2배 더 큰 손실(loss)를 부여

Parameter	Value
Batch size	8
Optimizer	AdamW
Learning rate	2e-5
Maximum sequence Length	300
Epochs	50

RoBERTa	precision	recall	F1-score	accuracy
Improved	0.90	0.97	0.93	0.90
mets	0.92	0.90	0.91	
no	0.91	0.91	0.91	
progression	0.83	1.00	0.91	
romets	0.88	0.81	0.84	
stable	0.97	0.85	0.91	

LLaMA 3.1

model_name = "meta-llamaMeta-Llama-3.1-8B"

- 모델: Llama 3.1
- 기반 모델: LLaMA (Large Language Model Meta AI)
- 데이터셋: A new mix of publicly available online data
- 주요 특징: 2024년 7월 23일 발표한 모델로 assistant-like chat 구현을 위해 학습된 모델
- 성능: MMLU(66.7% macro_avg/acc), TriviaQA(78.5% em), CommonSenseQA(72.6% acc_char)
- 주요 성과: 광범위한 도메인 벤치마크에서 좋은 성능을 입증하고 8개의 언어의 대한 추론이 가능

Parameter	Value
Batch size	6
Learning rate	1e-4
Maximum sequence Length	300
Epochs	20
R size	8
Lora alpha	8
Lora dropout	0.03
Quant type	8 bit

LLaMa 3.1	precision	recall	F1-score	accuracy
Improved	0.90	0.97	0.93	0.92
mets	0.97	0.95	0.96	
no	0.95	0.89	0.92	
progression	0.85	0.93	0.89	
romets	0.88	0.88	0.88	
stable	0.92	0.90	0.91	

BioGPT¹⁾

model_name = "Microsoft/biogpt"

- 모델: BioGPT
- 특화 도메인: 바이오메디컬/의료
- 기반 모델: GPT (Generative Transformer)
- 데이터셋: 대규모 바이오메디컬 문헌
- 주요 특징: 생성 능력을 갖춘 도메인 특화 모델, 6개의 바이오메디컬 자연어 처리 작업에서 우수한 성능
- 성능: BC5CDR(44.98% F1), KD-DTI(38.42% F1), DDI(40.76% F1), PubMedQA(78.2% 정확도)
- 주요 성과: 바이오메디컬 용어에 대한 유창한 텍스트 생성 가능, 새로운 기록 달성

Parameter	Value
Batch size	6
Learning rate	3e-4
Maximum sequence Length	300
Epochs	20
R size	8
Lora alpha	8
Lora dropout	0.03
Quant type	8 bit

BioGPT	precision	recall	F1-score	accuracy
Improved	0.93	0.93	0.93	0.92
mets	0.97	0.90	0.94	
no	0.93	0.93	0.93	
progression	0.83	0.97	0.89	
romets	0.88	0.88	0.88	
stable	0.95	0.90	0.92	

1) Luo, R., Sun, L., Xia, Y., Qin, T., Zhang, S., Poon, H., & Liu, T. Y. (2022). BioGPT: generative pre-trained transformer for biomedical text generation and mining. *Briefings in bioinformatics*, 23(6), bbac409.

BioLLaMA

model_name = "aaditya/OpenBioLLM-Llama3-8B"

- 모델: OpenBioLLM-8B (80억 매개변수)
- 특화 도메인: 바이오메디컬/의료
- 기반 모델: Meta-Llama-3-8B
- 주요 기술: Direct Preference Optimization (DPO), Nectar 데이터셋, 맞춤형 의료 지침 데이터셋
- 성능: 바이오메디컬 작업에서 평균 정확도 72.5% (GPT-3.5 및 Meditron-70B보다 우수)
- 용도: 오픈 소스, 의료 및 생명과학 분야 연구 및 개발에 적합

Parameter	Value
Batch size	6
Learning rate	3e-4
Maximum sequence Length	300
Epochs	30
R size	8
Lora alpha	8
Lora dropout	0.03
Quant type	8 bit

BioLLaMa	precision	recall	F1-score	accuracy
Improved	0.88	1.00	0.94	0.93
mets	0.95	0.95	0.95	
no	0.98	0.93	0.95	
progression	0.90	0.90	0.90	
romets	0.89	0.92	0.91	
stable	0.97	0.90	0.94	

BioMistral¹⁾

model_name = "bioMistral/bioMistral-7b"

- 모델: BioMistral/BioMistral-7B
- 특화 도메인: 의료/바이오메디컬
- 기반 모델: Mistral
- 데이터셋: PubMed Central Open Access (CC0, CC BY, CC BY-SA, CC BY-ND)
- 주요 특징: 10개의 의료 QA 작업에서 우수한 성능, 기존 모델 및 상용 모델 대비 경쟁력 있음
- Multilingual 평가: 7개 언어로 자동 번역 및 평가, 최초의 대규모 다국어 의료 LLM 평가

Parameter	Value
Batch size	6
Learning rate	3e-4
Maximum sequence Length	300
Epochs	30
R size	8
Lora alpha	8
Lora dropout	0.03
Quant type	8 bit

BioMistral	precision	recall	F1-score	accuracy
Improved	0.85	0.97	0.90	0.89
mets	0.90	0.93	0.91	
no	0.95	0.87	0.91	
progression	0.93	0.90	0.92	
romets	0.85	0.85	0.85	
stable	0.85	0.85	0.85	


1) Labrak, Y., Bazoge, A., Morin, E., Gourraud, P. A., Rouvier, M., & Dufour, R. (2024). Biomistral: A collection of open-source pretrained large language models for medical domains. *arXiv preprint arXiv:2402.10373*.

04 최종 모델 소개

Combination	F1	Accuracy
biobert	0.9156	0.9190
llama3.1	0.9166	0.9190
biogpt	0.9010	0.9047
roberta	0.9019	0.9047
biomist	0.8835	0.8857
biollama	0.9301	0.9333
biobert, llama3.1	0.9353	0.9380
biobert, biogpt	0.9198	0.9238
biobert, roberta	0.9114	0.9142
biobert, biomist	0.9022	0.9047
biobert, biollama	0.9377	0.9428
llama3.1, biogpt	0.9302	0.9333
llama3.1, roberta	0.9296	0.9333
llama3.1, biomist	0.9015	0.9047
llama3, biollama	0.9438	0.9476
biogpt, roberta	0.9006	0.9047
biogpt, biomist	0.9162	0.9190
biogpt, biollama	0.9389	0.9428
roberta, biomist	0.9168	0.9190
roberta, biollama	0.9373	0.9428
biomist, biollama	0.9095	0.9142
biobert, llama3.1, biogpt	0.9392	0.9428


Combination	F1	Accuracy
biobert, llama3.1, roberta	0.9441	0.9476
biobert, llama3.1, biomist	0.9002	0.9047
biobert, llama3.1, biollama	0.9438	0.9476
biobert, biogpt, roberta	0.9312	0.9333
biobert, biogpt, biomist	0.9095	0.9142
biobert, biogpt, biollama	0.9384	0.9428
biobert, roberta, biomist	0.9161	0.9190
biobert, roberta, biollama	0.9433	0.9476
biobert, biomist, biollama	0.9235	0.9285
llama3.1, biogpt, roberta	0.9342	0.9380
llama3.1, biogpt, biomist	0.9088	0.9142
llama3.1, biogpt, biollama	0.9390	0.9428
llama3.1, roberta, biomist	0.9191	0.9238
llama3.1, roberta, biollama	0.9487	0.9523
biogpt, roberta, biomist	0.9151	0.9190
biogpt, roberta, biollama	0.9482	0.9523
biogpt, biomist, biollama	0.9185	0.9238
roberta, biomist, biollama	0.9280	0.9333
biobert, llama3.1, biogpt, roberta	0.9405	0.9428

Combination	F1	Accuracy
biobert, llama3, biogpt, biomist	0.9249	0.9285
biobert, llama3.1, biogpt, biollama	0.9493	0.9523
biobert, llama3.1, roberta, biomist	0.9245	0.9285
biobert, llama3.1, roberta, biollama	0.9483	0.9523
biobert, llama3.1, biomist, biollama	0.9330	0.9380
biobert, biogpt, roberta, biomist	0.9197	0.9238
biobert, biogpt, roberta, biollama	0.9434	0.9476
biobert, biogpt, biomist, biollama	0.9182	0.9238
biobert, roberta, biomist, biollama	0.9381	0.9428
llama3.1, biogpt, roberta, biomist	0.9204	0.9238
llama3.1, biogpt, roberta, biollama	0.9592	0.9619
llama3.1, biogpt, biomist, biollama	0.9236	0.9285
llama3.1, roberta, biomist, biollama	0.9277	0.9333
biogpt, roberta, biomist, biollama	0.9280	0.9333
biobert, llama3.1, biogpt, roberta, biomist	0.9245	0.9285
biobert, llama3.1, biogpt, roberta, 'biollama	0.9482	0.9523
biobert, llama3.1, biogpt, biomist, biollama	0.9333	0.9380
biobert, llama3.1, roberta, biomist, biollama	0.9331	0.9380
biobert, biogpt, roberta, biomist, biollama	0.9281	0.9333
llama3.1, biogpt, roberta, biomist, biollama	0.9279	0.9333
biobert, llama3.1, biogpt, roberta, biomist, biollama	0.9379	0.9428




*최종 모델 : Llama3 + biogpt + Roberta + biollama


*Best ensemble model	Precision	Recall	F1-score	AUROC	Accuracy
Improved	0.94	1.00	0.97	0.999	0.962
mets	1.00	0.95	0.97	0.996	
no	0.98	0.98	0.98	0.997	
progression	0.91	1.00	0.95	0.998	
romets	0.92	0.92	0.92	0.990	
stable	1.00	0.93	0.96	1.000	
weighted avg	0.96	0.96	0.96	0.997	0.962




improved




no




romets




mets



progression



stable



- Text input 입력 시 자동 전처리

- 불용어, 줄바꿈, 특수문자 제거
- 소문자로 변경

- 4개의 모델이 차례대로 로드되어 logit값 계산

- 각 모델은 input text에 대한 logit값 계산 후 unload

- 각 모델의 logit값을 소프트 보팅하여 최종 라벨 선택



암 치료 반응 분류 모델

암 반응 텍스트를 입력하면 모델이 해당 반응을 분류합니다.

암 반응 텍스트를 입력하세요

Clinical information: Pancreatic Cancer, metastatic

Findings: Compared to 2020-02-28 MRI. Decreased size of the mass lesion on the T11. Newly developed mass metastasis on C5, L2-3.

Conclusion: Multiple spinal metastasis. C5. T11. L2-3.

예측

○ 예측 중...



암 치료 반응 분류 모델

암 반응 텍스트를 입력하면 모델이 해당 반응을 분류합니다.

암 반응 텍스트를 입력하세요

Clinical information: Pancreatic Cancer, metastatic

Findings: Compared to 2020-02-28 MRI. Decreased size of the mass lesion on the T11. Newly developed mass metastasis on C5, L2-3.

Conclusion: Multiple spinal metastasis. C5. T11. L2-3.

예측


모델 결과: progression 입니다.

05

XAI를 통한 토큰 분석


romets

Prediction probabilities



NOT romets


romets



Text with highlighted words


exam whole spine mri contrast enhancement clinical information lung cancer stage3 sp ccrt 202267 findings bone marrow replacing mass l5 t2 hyperintensity t1 hypointensity homogeneous enhancement t1 hyperintense lesion enhancement anterior aspect c3 t1 low signal intensity linear line coccyx suggestive coccygeal vertebra several enhancing masses brain suggesting metastases conclusion ro bone metastasis l5 coccygeal fracture recommendation clinical correlation

Prediction probabilities



NOT romets

romets



Text with highlighted words

exam whole spine mri contrast enhancement clinical information cervix cancer back pain findings small enhancing nodular lesion anterior body l4 vertebra abutting lower endplate multiple schmorls nodes without bone marrow edema contrast enhancement lumbar vertebrae evidence signal change spinal cord significant spinal stenosis conclusion ro acute schmorls node l4 ddx bone metastasis less likely recommendation clinical correlation

LIME으로 살펴보았을 때, 'romets'으로 맞추기 위해 LLM이 주목한 토큰

1. ro (0.41%)

**rule out: 검사를 진행중이거나 의심이 되는 증상을 보임

2. conclusion (0.20%)

3. t1 (0.15%)

4. recommendation (0.13%)


5. t2 (0.09%)

progression



Text with highlighted words

exam whole spine mri contrast enhancement clinical information lung cancer squamous cell cancer bone metastasis sp palliative rtx spne20209 comparison outside mri scanned 20201120 good morning hospital findings bone marrow replacing enhancing lesion t3 t4 pathologic fracture t3 t4 newly developed newly developed bone marrow replacing lesion enhancement superior endplate t5 bulging discs c56 c67 conclusion metastatic bone lesion involving t3 t5 vertebral bodies pathologic fracture t3 t4 recommendation clinical correlation follow



Text with highlighted words


exam whole spine mri contrast enhancement clinical information lung cancer squamous cell cancer bone metastasis sp palliative rtx spne20209 comparison outside mri scanned 20201120 good morning hospital findings bone marrow replacing enhancing lesion t3 t4 pathologic fracture t3 t4 newly developed newly developed bone marrow replacing lesion enhancement superior endplate t5 bulging discs c56 c67 conclusion metastatic bone lesion involving t3 t5 vertebral bodies pathologic fracture t3 t4 recommendation clinical correlation follow

LIME으로 살펴보았을 때, 'progression'으로 맞추기 위해 LLM이 주목한 토큰

1. developed (0.36%)
2. newly (0.31%)
3. t3 (0.1%)
4. lesion (0.1%)
5. replacing (0.08%)
6. metastatic (0.08%)


improved

Prediction probabilities



NOT improved


improved



Text with highlighted words

exam whole spine mri contrast enhancement clinical information breast cancer multiple bone metastasis comparison 20210329 mri findings **recovered** bone marrow **signal decreased** nodular enhancing lesion l45 body otherwise interval change bone marrow replacing enhancing lesions whole spine pelvic bones sternum ribs scanned area remarkable findings spinal cord **impression** **slightly improved** bone metastasis recommend clinical correlation follow

Prediction probabilities



NOT improved

improved



Text with highlighted words


exam whole spine mri contrast enhancement clinical information lt rcc sp lt radical nephrectomy 20070115 **rt** rcc sp **rt** partial nephrectomy 20120405 sp palliative rtx c6 t1 spine 20210315319 comparison 20211022 mri findings change **slightly decrease** enhancement t2 hypersignal intensity previously seen metastatic lesions c7 l1 vertebra lt t10 rib right neural foramen t1112 pathologic fracture t12 l1 vertebral bodies compressed sp posterior instrumentation l345s1 findings show interval change conclusion change **slightly improved** metastatic bone lesions pathologic fracture t12 l1 vertebral bodies compressed **recommendation** clinical correlation

LIME으로 살펴보았을 때, 'improved'으로 맞추기 위해 LLM이 주목한 토큰


1. improved (0.43%)
2. decreased (0.42%)
3. slightly (0.13%)
4. recovered (0.10%)
5. impression (0.08%)

no

Prediction probabilities




NOT no




Text with highlighted words

exam whole spine mri enhancement **evidence** bone marrow replacing lesion bulging disc decreased height disc I34 I45 **I5s1** left lateral recess stenosis I34 I45 levels bulging disc c45 c56 c67 **unremarkable** finding spinal cord impression 1 **evidence** bony metastasis 2 degenerative change cspine **Ispine** left lateral recess stenosis I34 I45 levels **recommendation** clinical **correlation**

Prediction probabilities



NOT no



Text with highlighted words


exam whole spine mri contrast enhancement clinical comment gallbladder cancer c multiple liver **metastasis** findings disc bulging c34 c45 c56 causing central canal stenosis **evidence** cord signal change disc bulging ligamentum flavum thickening facet joint hypertrophy I23 I34 I45 causing central stenosis loss normal cervical lumbar lordosis underlying discovebral degeneration discernible bone marrow replacing lesion impression 1 **definite** **evidence** bone **metastasis** 2 central canal stenosis c34 c56 I23 **I45**

LIME으로 살펴보았을 때, 'no'으로 맞추기 위해 LLM이 주목한 토큰


1. evidence (0.21%)
2. correlation (0.11%)
3. I5s1(0.07%)
4. Ispine (0.06%)
5. unremarkable (0.12%)

mets

Prediction probabilities




NOT mets




Text with highlighted words

exam whole spine contrast enhanced mri patient history lung cancer findings multiple marrowreplacing lesions including t10 t12 l2345 s12 right ilium t1 low signal intensity lesions t3 t6 clinical significance indeterminate evidence cord compression conclusion multiple bone metastases

Prediction probabilities



NOT mets



Text with highlighted words


exam whole spine contrast enhanced mri patient history advanced gastric cancer agc findings multiple metastatic lesions c l spines sternum pelvic bone evidence spinal cord compression conclusion multiple bone metastases

LIME으로 살펴보았을 때, 'mets'으로 맞추기 위해 LLM이 주목한 토큰

1. metastases (0.35%)
2. cord (0.18%)
3. whole (0.13%)
4. clinical (0.09%)
5. conclusion (0.08%)


stable

Prediction probabilities



NOT stable


stable



Text with highlighted words


exam whole spine mri contrast enhancement clinical information angiosarcoma arising teratoma chemo effect sp rtx c5 sp laminectomy posterior fusion epidural metastasis removal cspine 20200422 compared previous mri taken 20200909 findings sp laminectomy c567 posterior fixation c347t1 change decreased kyphotic curve central canal narrowing cord compression c5 level significant change pathologic compression fracture c5 body slightly decreased extent soft tissue masses prevertebral central canal cervical level definite cord signal change significant change multiple bone marrow replacing lesions whole spine enhancement conclusion sp laminectomy c567 posterior fixation c347t1 stable disease recommendation clinical correlation

Prediction probabilities



NOT stable

stable



Text with highlighted words

exam whole spine mri contrast enhancement clinical information angiosarcoma arising teratoma chemo effect sp rtx c5 sp laminectomy posterior fusion epidural metastasis removal cspine 20200422 compared previous mri taken 20200909 findings sp laminectomy c567 posterior fixation c347t1 change decreased kyphotic curve central canal narrowing cord compression c5 level significant change pathologic compression fracture c5 body slightly decreased extent soft tissue masses prevertebral central canal cervical level definite cord signal change significant change multiple bone marrow replacing lesions whole spine enhancement conclusion sp laminectomy c567 posterior fixation c347t1 stable disease recommendation clinical correlation

LIME으로 살펴보았을 때, 'stable'으로 맞추기 위해 LLM이 주목한 토큰

1. stable (0.6%)
2. compression (0.08%)
3. recommendation (0.07%)
4. significant (0.06%)
5. change (0.05%)

Romets (병이 있어 정밀검사 필요)

- 워드클라우드 : "ro", "excluded", "less", "metastasis", "narrowing"
- TF-IDF : "ro", "t1", "t2", "intensity"
- LIME : "ro", "conclusion", "t1", "recommendation", "t2"

Progression (암이 진행됨)

- 워드클라우드 : "marrowreplacing", "bone", "suspected"
- TF-IDF : "metastases", "enhanced", "marrowreplacing"
- LIME : "developed", "newly", "t3", "lesion"

Improved (암 치료 후 호전됨)

- 워드클라우드 : "decreased", "slightly", "improved", "showing", "resolving"
- TF-IDF : "decreased", "extent", "slightly", "wholespine"
- LIME : "improved", "decreased", "slightly", "impression"

No (암 부재 또는 처음부터 암이 없었음)

- 워드클라우드 : "increased", "progressed", "appeared", "aggravated", "extending"
- TF-IDF : "increased", "newly", "mass", "metastatic", "pathologic"
- LIME : "evidence", "correlation", "l5s1", "lspine", "unremarkable"




Mets (새로운 전이 발생)

- 워드클라우드 : "marrowreplacing", "bone", "enhancing", "suspected", "indetermined"
- TF-IDF : "metastases", "enhanced", "marrowreplacing", "patient", "history"
- LIME : "metastases", "cord", "whole", "clinical", "conclusion"

Stable (치료 이후 암이 진행되지 않고 안정적인)

- 워드클라우드 : "seeding", "fractures", "multiple", "radiotherapy", "relatively", "included"
- TF-IDF : "interval", "significant", "leptomeningeal", "remarkable"
- LIME : "stable", "compression", "recommendation", "significant", "change"

TNM System for Staging Breast Cancer

T  Tumor size	N  Lymph Node Status	M  Metastasis
T-1: 0-2 centimeters T-2: 2-5 centimeters T-3: >5 centimeters T-4: Tumor has broken through skin or attached to chest wall	N-0: Surgeon can't feel any nodes N-1: Surgeon can feel swollen nodes N-2: Nodes feel swollen and lumpy N-3: Swollen nodes located near collarbone	M-0: Tested nodes are cancer-free M-1: Tested nodes show cancer cells or micrometastasis

T = 원발 종양에 대한 Description

N = 림프노드 침범 개수

M = metastasis 전이

**tnm stage: 거의 모든 암에 존재하며 암마다 세부 기준이 완전히 다름
(ex. 몇센치 침범이 암마다 다름)

No

- 'No' 라벨에 존재하는 주요 토큰 중 "evidence"와 "definite"는 암의 존재 여부를 평가하는 데 중요한 단어들로, **암에 대한 증거가 없거나 부재함**을 나타내고 있음

Progression

- Progression 단계는 T3가 언급된 점으로 보아 **T3, T4** 상태로 진행되어 상대적으로 큰 종양으로 주변 조직으로 확산된 상태를 나타냄

Improved

- 'Improved' 단계에서 "decreased"가 상위에 나타나는 점은 종양의 크기와 줄어들었음을 의미하며, **T단계에서 감소했음**을 시사함

Romets

- Romets는 주로 전이 가능성이 있는지에 집중하여 보기 때문에 **T1, T2**가 언급된 점으로 보아, 상대적으로 작은 종양이지만 추가 확산 여부를 확인하기 위해 정밀검사가 필요

Mets

- Mets는 **T4 또는 M1** 상태와 관련이 있으며 종양이 주변 조직을 넘어서 확산되었거나 전이가 발생한 상태임
- "marrowreplacing"과 같은 용어는 골수 전이를 시사하며, 암이 전이된 상태에서 추가적인 치료가 필요함을 나타냄

Stable

- 'Stable' 상태는 T단계에서 더 이상 변동이 없으며, **치료 후 종양이 줄어들거나 안정화된** 상태로, 암의 확산이 멈춘 상태를 의미함

06

결론 및 제언

구축 모델 결론

1

[모델 선택 기준]

의료 산업에 특화된 LLM 모델 사용

텍스트 분류 작업에 특화된 BERT 계열 모델 사용

2

[Fine tuning]

QLoRA 통해 모델을 양자화하여, 모델의 성능은 유지하면서 더 적은 컴퓨팅 자원으로 미세조정

Hyper-parameter tuning을 통해 최적의 파라미터를 도출함

3

[구축 모델 활용 방안]

분석 배경에서 제시한 바와 같이, 최근 의학계에서는 병명 진단에 AI를 적극적으로 활용하고 있음

이에 우리가 구축한 모델도 의학계에서 활용한다면, 의사들이 편리하게 진단 결과를 해석할 수 있고,

환자들에게 개인화된 맞춤형 치료를 통해 더 나은 의료 서비스를 제공할 수 있음

Strengths (강점)

- **기술적 우위**: 의료 산업에 특화된 LLM과, 분류 작업에 특화된 BERT 계열 언어 모델을 QLoRA로 효율적으로 fine-tuning하고, 앙상블하여 성능을 크게 향상 시킴
- **의사 활용성 증가**: 의사들이 진단 결과를 보다 쉽게 해석하고, 환자 맞춤형 솔루션을 제공하는 데 기여할 수 있음

Weakness (약점)

- **서버 자원 부족**: 대규모 데이터 처리와 모델 학습에 필요한 서버 자원이 부족하여 다양하고 큰 모델을 사용하기에 한계가 있음
- **데이터 부족**: 충분한 양의 라벨링된 의료 데이터가 부족하여 LLM만을 사용한 모델 성능이 제한적임

SWOT

Opportunity (기회)

- **서버 자원 확장**: 서버 자원 확충을 통해 더 강력한 LLM 모델을 사용하여 강력한 모델을 사용하면 성능을 크게 향상시킬 수 있는 기회가 존재함
- **데이터 구축을 위한 의학과와의 파트너십 구축**: 의사와의 협업을 통해 의료 데이터와 치료 방안 데이터를 구축할 수 있음 이를 바탕으로 모델을 튜닝하여 환자 맞춤형 솔루션과 치료를 위한 구체적인 방안을 제시할 수 있음

Treats (위협)

- **데이터 규제**: 의료 데이터의 프라이버시 및 보안 관련 규제가 강화될 가능성이 있으며, 이는 데이터 수집 및 사용에 제약이 발생
- **기술 발전 속도**: 인공지능 및 의료 기술의 급속한 발전으로 인해 현재 모델이 빠르게 구식될 수 있는 위험이 있음

목표 설정 SMART 기법

S

Specific(구체적 목표)

[의사 진단 보조 AI 챗봇 구축]
모델이 의료 진단 과정에서 중요한 정보를 제공하고, 할루시네이션을 줄여 의사에게 신뢰성 있는 정보를 제공하도록 튜닝하고자 함.

M

Measurable(측정 가능성)

[할루시네이션 감소 및 성능 향상]
할루시네이션 발생률을 구체적으로 측정하여 이를 최대한 낮추는 것을 목표로 함. 분류 성능은 정확도를 기준으로 98% 이상 달성을 목표.

A

Achievable(달성 가능성)

설명 데이터를 활용한 instruction 튜닝을 통해 할루시네이션을 최대한으로 줄임.
여기서 설명 데이터란 데이터가 왜 특정 라벨로 분류 됐는지에 대한 정답 데이터를 의미.

R

Relevant(관련성)

의료 AI는 진단 과정에서 큰 도움을 주고 있으며, 이 목표 달성을 통해 LLM이 더 신뢰성 있는 진단 도구로 자리잡게 하여 현재 의료계의 중요한 목표를 달성하도록 도움.

T

Time-bound(기한설정)

데이터 구축 : 12개월 내
모델 성능 개선 : 6개월 내