

CoNSIST : Consist of New methodologies on AASIST, leveraging Squeeze-and-Excitation, Positional Encoding, and Re-formulated HS-GAL

발표자: 하재훈



연세대학교
YONSEI UNIVERSITY

목차

1. Background
2. Methodology
3. Experiment
4. Conclusion

Background

01. Background

Audio deepfake란?

- 오디오 딥페이크란 **인공지능 기술(딥러닝 기반)**을 사용하여 **음성 샘플을 조작**하거나 **합성**하여 실제 사람이 발화한 것처럼 만들어 내는 것
- Audio deepfake는 **범죄 등에 악용**되어 다양한 피해 사례가 발생.
- 이러한 피해 사례를 예방하기 위해 Audio deepfake 탐지 기술에 대한 연구가 필요.

국내외 딥보이스 주요 피해 사례

- ✓ 2019년 3월 영국 기업이 고위 임원 목소리를 딥보이스에 속아 22만 유로(약 2억 9800만원) 송금
- ✓ 2021년 10월 아랍에미리트(UAE) 은행이 고위 임원 목소리를 도용한 딥보이스에 속아 3500만달러(약 420억원) 송금
- ✓ 2021년 1월 '딥보이스 통한 섹스테이프 제작 처벌해달라' 청와대 국민청원 글 게시
- ✓ 2022년 3월 '젤렌스키 우크라이나 대통령 항복선언' 딥페이크 영상

국내외 딥보이스 주요 피해 사례

- ✓ 2019년 3월 영국 기업이 고위 임원 목소리를 딥보이스에 속아 22만 유로(약 2억 9800만원) 송금
- ✓ 2021년 10월 아랍에미리트(UAE) 은행이 고위 임원 목소리를 도용한 딥보이스에 속아 3500만달러(약 420억원) 송금
- ✓ 2021년 1월 '딥보이스 통한 섹스테이프 제작 처벌해달라' 청와대 국민청원 글 게시
- ✓ 2022년 3월 '젤렌스키 우크라이나 대통령 항복선언' 딥페이크 영상

01. Background

누구나 악용이 가능하다?

- Audio deepfake 기술이 발전함에 따라 다양한 분야에 적용되고 있으며, 일반인들도 접근하기 쉬움.
- 가족이나 친구, 직장 동료 등 **소중한 사람들의 목소리를 악용**하여 다양한 범죄에 사용할 수 있음.
- 이러한 악용을 예방하기 위해 딥보이스 탐지 모델링 수행.



“늦은 시간에 전화했네 !!”

01. Background

오디오 딥페이크 종류

- 오디오 딥페이크의 종류는 크게 2가지로 나뉨
- **Text-to-Speech(TTS; 텍스트 음성 합성)**: 텍스트를 주고 기계 학습 기반 모델로 음성을 합성하는 것
- **Voice Conversion(VC; 음성 변환)**: 특정 화자의 발화 음성을 주고 다른 화자의 음성으로 합성하는 것
- 딥러닝 기술이 발전함에 따라 더욱 진짜 사람 같은 음성을 합성할 수 있게 됨

오디오 딥페이크 탐지 연구 현황

- 오디오 딥페이크 기술의 발전에 따른 피해를 방지하고자, 오디오 딥페이크 탐지 연구의 필요성이 대두됨
- 학계에서는 더욱 체계적인 연구를 위해 오디오 딥페이크 탐지 경연대회를 개최함
- **ASVspoof**: *ASV 시스템을 공격으로부터 보호하는 관점에서 스푸핑 된 오디오를 탐지하는 데 중점
- **ADD challenge**: 저음질 딥페이크, 부분 딥페이크 등을 탐지

*ASV: 자동 화자 검증, 음성 분석을 수행하여 개인을 인증하는 시스템

벤치마크

[illegible]

01. Background

☞ 딥페이크 탐지 모델은 특성 추출기와 분류기로 구성된 Pipeline 모델, 모든 task를 하나로 통합한 End-to-end 모델로 분류할 수 있음

Pipeline

Traditional Classification

- ▶ Logistic Regression, SVM, Random Forest, KNN 기반
- 특징 추출 후 전통적인 머신러닝 알고리즘을 사용하여 분류
- SVM 분류기는 본질적으로 인공적인 스푸핑 공격 분류에 강함
- 그러나, 실제 시나리오에서 스푸핑 공격의 특징을 파악하기 어려움
- GNN 기반 분류기는 ASVspoof, ADD 경진대회에서 효과적인 성능을 보여 널리 사용됨

Deep Learning Classification

- ▶ CNN, ResNet, SENet, GNN, Transformer 기반
- 특징 추출 후 딥러닝 알고리즘을 사용하여 분류
- 전통적인 머신러닝 알고리즘 분류기보다 뛰어난 성능을 보임
- CNN 기반 모델은 공간-지역적 특징을 잘 포착해 효과적임
- GNN 기반은 데이터 간의 관계를 학습하여 분류하여 효과적임

- ✓ AASIST 기반 모델은 ASVspoof, ADD 경진대회에서 SOTA를 달성
- ✓ 본 연구에서는 AASIST를 기반으로 한 모델링을 통해 성능 향상을 도모하였음

End-to-end

CNN-based

- ▶ CLDNN, CRNNSpooof, TSSDNet 등
- 단일 CNN과 MLP 계층으로 구성
- VC, TTS 공격에 대해 우수한 성능을 보였으나, 일반화 성능이 좋지 않음

ResNet-based

- ▶ Res-TSSDNet, RW-ResNet 등
- Residual mapping을 사용
- 훈련이 쉬워지고 유망한 성능을 보임

Transformer-based

- ▶ Rawformer, SE-Rawformer 등
- Convolution layer와 transformer로 구성
- Local 및 global 관계를 모델링하여 일반화 성능이 향상함

GNN-based

- ▶ RawGAT-ST, AASIST 등
- 오디오 데이터를 시간-스펙트럼 그래프로 모델링하여 그래프 어텐션 연산 사용
- 그래프 간의 복잡한 관계를 모델링하여 오디오 딥페이크 여부를 효과적으로 포착함


01. Background

☞ 베이스라인 모형인 AASIST는 다음과 같음

AASIST

AASIST (Audio Anti-Spoofing using Integrated Spectro-Temporal Graph Attention Networks)

- ✓ 'RawGAT-ST'의 그래프 구조를 'HS-GAL(Heterogeneous Stacking Graph Attention Layer)'과 결합한 모델
- ✓ 2019 ASVspoof, 2023 ADD 대회에서 SoTA를 달성
- ✓ 오디오 파일의 raw-waveform을 **spectral**과 **temporal** 축으로 나누어 서로간의 어텐션(연결 강도) 연산을 통해 분류



Methodology


02. Methodology

☞ AASIST를 디벨롭한 모형인 우리 모델(CoNSIST)은 다음과 같음

CoNSIST (ours)

✓ AASIST를 기본 모형으로 선정하여 **세 가지** 개선 방안을 구축 및 모델링

1. Squeeze and Excitation
2. Positional Encoding
3. Reformulated HS-GAL




02. Methodology

Methodology

1. Squeeze-and-Excitation Encoder

- ✓ 기존 6개의 residual encoder block들에 CNN 아키텍처에서 주로 사용되는 SE 연산을 추가
- ✓ 각 채널의 중요도에 따라 **feature map의 각 요소에 가중치**를 적용하여 중요한 feature를 학습하고, 더 큰 가중치를 부여
 - Squeeze : 채널의 feature를 **global average pooling**을 통해 하나의 숫자로 압축
 - Excitation : 1×1 합성곱을 사용하여 각 채널에 대한 가중치를 학습
 - Scale : 각 채널에 대한 가중치를 사용하여 기존의 feature map을 재조정




02. Methodology


Methodology

2. Positional Encoding

- ✓ Feature map을 추출하고 그래프로 변환하는 과정에서 위치 정보를 주입
- ✓ $\text{Max}(\text{abs}(F))$ 연산의 결과로 생성된 **Spectral/Temporal feature map**에 **각각 위치 정보 Encoding vector**를 더함
 - 인코딩 벡터 차원 : Spectral (1x23), Temporal (1x29)
- ✓ Embedding 방식은 학습 과정이 더 복잡해지고 학습 시간이 늘어날 것을 대비하여 **Encoding 방법론**을 선택
- ✓ 위치 정보 계산 수식은 트랜스포머 모델과 동일하게 Sin, Cos함수 사용



Positional Encoding




02. Methodology

Methodology


3. Reformulated HS-GAL

- ✓ HS-GAL (Heterogeneous Attention Layer) 에서 동종 그래프 어텐션 연산을 제거하고, Stack node를 추가하여 모델의 성능 개선
 - Graph Module에서 이미 동종 (Spectral은 Spectral끼리, Temporal은 Temporal끼리) 어텐션 연산을 하여 노드간의 연결 강도를 학습하였고, 중요하지 않은 노드 정보는 버리는 작업을 진행
 - HS-GAL에서 중복적으로 동종 어텐션 연산은 파라미터의 수만 늘릴 뿐 최종 분류 작업에 큰 영향을 미치지 않을 것으로 판단
 - Stack node는 다른 모든 노드들의 정보를 포함하고 있는 노드로, BERT의 CLS 토큰과 비슷한 역할을 함
 - 동종 그래프 어텐션은 제거하고, Stack node의 개수를 4개로 증가



AASIST

Reformulated HS-GAL



CoNSIST(ours)

Experiment


03. Experiment

데이터셋

ASVspoof 2019의 Logical Access(LA) 데이터셋

- ✓ ASVspoof Challenge: Spoofing(합성)된 오디오를 탐지하는데 중점을 둔 대회
- ✓ 텍스트 음성 합성(Text-to-Speech, TTS) 및 음성 변환(Voice Conversion, VC) 알고리즘을 사용하여 생성된 “실제”와 “합성”된 영어 발화체(utterance)들을 포함하고 있음
- ✓ AASIST와 CoNSIST 모두 해당 데이터셋을 사용

- **Training Set:** 4개의 TTS와 2개의 VC로 만든 22,800개의 Spoofed된 데이터와, 2,580개의 bona-fide 음성 데이터
- **Development Set:** 22,286개의 Spoofed된 데이터와, 2,548개의 bona-fide 음성 데이터
- **Evaluation Set:** 7개의 TTS와 6개의 VC로 만든 63,882개의 Spoofed된 데이터와, 7,335개의 bona-fide 음성 데이터




03. Experiment

- Dataset : ASVspoof 2019 LA (AASIST와 동일)
- Metric
 - Min t-dcf (Minimum tandem detection cost function)¹ : ASV 와 CM의 오차를 모두 결합하여 단일 지표로 측정
 - $C_1 P_{miss}^{cm}(s) + C_2 P_{fa}^{cm}(s)$
 - $P_{miss}^{cm}(s) = \frac{\#\{\text{bona fide trials with CM score} \leq s\}}{\#\{\text{Total bona fine trials}\}}$
 - $P_{fa}^{cm}(s) = \frac{\#\{\text{spoof trials with CM score} > s\}}{\#\{\text{Total spoof trials}\}}$
 - EER (Equal Error Rate) : 오인식률(FAR, False Acceptance Rate)과 오거부율(FRR, False Rejection Rate)이 같아지는 비율
 - $P_{fa}^{cm}(s_{EER}) = P_{miss}^{cm}(s_{EER})$

→ 두 Metric 모두 값이 낮을 수록 성능이 높은 것을 의미함

¹Kinnunen, T, et. al., (2018), T-DCF: A detection cost function for the tandem assessment of spoofing countermeasures and automatic speaker verification




✓ 두 지표 모두에서 성능이 개선됨을 확인 할 수 있음

03. Experiment

실험 결과

CoNSIST v AASIST

* A07~19는 각각 다른 TTS, VC 기술을 의미 (EER 기준)



✓ 13개의 각기 다른 TTS, VC 기술로 생성된 데이터셋에서 9개 부분에서 성능을 향상시킴

Conclusion

04. Conclusion

- 본 연구에서는 베이스라인 모형(AASIST)의 아키텍처를 변경한 개선모형을 설계하고 실험을 통해 성능을 검증함으로써 유의미한 성능 개선을 달성하였음.
- 개선방안 3종(SE Encoder, Positional encoding, Re-formulated HS-GAL)은 개별 적용 시에도 베이스라인 모형 보다 우수한 성능을 보였으며, 특히 개선방안 3종을 모두 적용한 결합모형(CoNSIST)의 성능이 가장 우수하였음.
- 다만, 제한된 시간 및 실험환경의 제약으로 충분한 실험을 수행하지 못한 부분이 있으며, 추가 실험을 통해 다음 사항을 보완할 경우 모형의 성능을 더욱 개선할 수 있을 것으로 기대됨.
 - 별도의 데이터셋(Asvspoof 2021)을 통해 모형의 일반화 성능을 측정/비교
 - 하이퍼 파라미터 튜닝을 통해 최적의 하이퍼 파라미터 도출

Reference

1. Yi, Jiangyan, et al. "Audio Deepfake Detection: A Survey." *ArXiv (Cornell University)*, 28 Aug. 2023,
2. Jung, Kyunghoon, and Changhyun Kim. "Beware of Voice Cloning: Deep Voice Crime Steals 400 Billion Won." *Moneytoday*, 11 Feb. 2023, news.mt.co.kr/mtview.php?no=2023020913433930492.
3. Jung, Jee-weon, et al. "AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks." *ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 23 May 2022, <https://doi.org/10.1109/icassp43922.2022.9747766>.
4. Hamza, Ameer, et al. "Deepfake Audio Detection via MFCC Features Using Machine Learning." *IEEE Access*, vol. 10, 2022, pp. 134018–134028, <https://doi.org/10.1109>.
5. Lataifeh, Mohammed, and Ashraf Elnagar. "Ar-DAD: Arabic Diversified Audio Dataset." *Data in Brief*, Nov. 2020, p. 106503, <https://doi.org/10.1016/j.dib.2020.106503>.
6. Borrelli, Clara, et al. "Synthetic Speech Detection through Short-Term and Long-Term Prediction Traces." *EURASIP Journal on Information Security*, vol. 2021, no. 1, 6 Apr. 2021, <https://doi.org/10.1186/s13635-021-00116-3>.
7. Arun Kumar Singh, and Priyanka Singh. "Detection of AI-Synthesized Speech Using Cepstral & Bispectral Statistics." *ArXiv (Cornell University)*, 3 Sept. 2020. Accessed 12 Apr. 2024.
8. Chintla, Akash, et al. "Recurrent Convolutional Structures for Audio Spoof and Video Deepfake Detection." *IEEE Journal of Selected Topics in Signal Processing*, vol. 14, no. 5, Aug. 2020, pp. 1024–1037, <https://doi.org/10.1109/jstsp.2020.2999185>.
9. Liu, Xiaohui, et al. Leveraging Positional-Related Local-Global Dependency for Synthetic Speech Detection. 4 June 2023, <https://doi.org/10.1109/icassp49357.2023.10096278>.
10. Tak, Hemlata, et al. "End-To-End Spectro-Temporal Graph Attention Networks for Speaker Verification Anti-Spoofing and Speech Deepfake Detection." *ArXiv (Cornell University)*, 1 Jan. 2021, <https://doi.org/10.48550/arxiv.2107.12710>.
11. Tak, Hemlata, et al. "Graph Attention Networks for Anti-Spoofing." *ArXiv (Cornell University)*, 30 Aug. 2021, <https://doi.org/10.21437/interspeech.2021-993>. Accessed 3 Apr. 2024.
12. Veličković, Petar, et al. "Graph Attention Networks." *arXiv (Cornell University)*, Feb. 2018, doi:10.17863/cam.48429.
13. Hu, Jie, et al. "Squeeze-and-Excitation Networks." *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, June 2018, doi:10.1109/cvpr.2018.00745.
14. Dufter, Philipp, et al. "Position Information in Transformers: An Overview." *Computational Linguistics*, vol. 48, no. 3, 2022, pp. 733–763, https://doi.org/10.1162/coli_a_00445. Accessed 4 Dec. 2022.
15. Vaswani, Ashish, et al. "Attention is All you Need." *arXiv (Cornell University)*, vol. 30, June 2017, pp. 5998–6008, arxiv.org/pdf/1706.03762v5.
16. Wang, Xin, et al. "ASVspoo 2019: A Large-Scale Public Database of Synthesized, Converted and Replayed Speech." *ArXiv (Cornell University)*, 4 Nov. 2019, <https://doi.org/10.48550/arxiv.1911.01601>.
17. Kinnunen, Tomi, et al. "T-DCF: A Detection Cost Function for the Tandem Assessment of Spoofing Countermeasures and Automatic Speaker Verification." *Odyssey 2018 the Speaker and Language Recognition Workshop*, 26 June 2018, www.isca-speech.org/archive/Odyssey_2018/pdfs/68.pdf, <https://doi.org/10.21437/odyssey.2018-44>.
18. Wang, Xin, and Junichi Yamagishi. "A Comparative Study on Recent Neural Spoofing Countermeasures for Synthetic Speech Detection." *ArXiv (Cornell University)*, 30 Aug. 2021, <https://doi.org/10.21437/interspeech.2021-702>.

Thank you for Watching!