

Incorporating Passage Importance in Retrieval-Augmented Generation Model: A Study on Passage Weighting Schemes

디지털 애널리틱스 융합협동 과정
석사 4학기 하재훈

INDEX

1. 연구 목적
2. 선행 연구
3. 연구 내용
4. 연구 결과
5. 결론

연구 목적

연구 목적

Introduction

- 수많은 LM(LLM) 모델들은 **implicit parametric knowledge**로 제작하다 보니 확장성과 저장 정보 수정을 하기 힘들.
- 새로운 정보로 업데이트 하려면 재학습이 필요함.
- 또한, 그럴듯한 오답을 생성하는 **hallucination** 현상이 빈번하게 일어남.



You

대한민국 축구 감독이 누구야?

우리나라 축구 감독이 누구야?



ChatGPT

2022년 1월까지의 정보로는 대한민국 축구 대표팀의 감독이 김종원이었습니다. 그러나 축구 감독은 상황에 따라 변경될 수 있으며, 특히 국제 대회가 끝난 후에 감독이 바뀔 수도 있습니다. 최신 정보를 확인하려면 현재 날짜를 기준으로 한 최신 뉴스나 공식 축구 관련 웹사이트를 참고하시기를 권장합니다.



사이트 5개 검색함 ▾

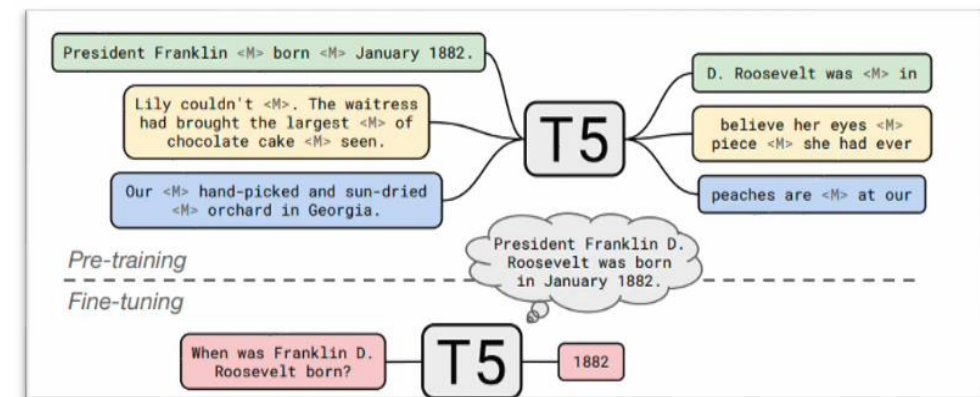

현재 대한민국 축구 국가대표팀 감독은 홍명보입니다. 그는 2024년 8월, 독일 출신의 전 감독 위르겐 클린스만의 후임으로 선임되었습니다. 홍명보는 울산 현대 감독으로 2022년과 2023년 K리그 우승을 이끌었던 경험이 있으며, 이번에 대한민국 대표팀의 새로운 축구 철학을 세우기 위해 KFA(대한 축구협회)로부터 신임을 받았습니다

INSIDE WORLD FOOTBALL TRANSFER MARKET

🔊 📄 📌 🔍 ↺

연구 목적


- Explicit Non-Parametric Knowledge : 외부 지식에서 답변을 찾는 태스크
 - ✓ 외부 지식을 직접 사용하기 때문에 지식을 사용자가 수정, 업데이트 가능
 - ✓ 답변을 KB에서 갖고 오기 때문에 답변 내용에 제한이 존재
- Implicit Parametric Knowledge : 질문에 대한 정보를 전혀 주지 않은 채, 모델에게 답변을 생성하도록 하는 태스크
 - ✓ 외부 지식에 접근할 필요가 없이 end-to-end로 추론가능
 - ✓ 생성 과정에서 지식을 직접 사용자가 수정 불가
 - ✓ 실제 지식과 관련 없는 hallucination등이 발생 가능



연구 목적

Semi-Parametric Model : RAG (Retrieval-Augmented Generation)

- Two Stage: Retrieval – Generator Approach



연구 목적

연구 목적과 기여

- Retrieval-Augmented Generation 모델은 검색된 패시지를 생성 과정에 포함시켜 자연어 처리의 고질적인 문제인 할루시네이션을 보다 더 완화시키고 다양한 task에서 좋은 성능을 보임.
 - 다만, **패시지의 점수와 순위를** 최종적으로 사용할 **k개의 패시지를 고를 때만 고려**하고, 제너레이터 부분에는 뽑힌 패시지를 동일하게 취급하는 한계를 갖고 있음.
- RAG 방법론으로 구성된 최적의 모델을 선정하여 패시지의 중요도를 효과적으로 반영하기 위한 **가중치 부여 방안**을 개발.
- 패시지에 중점을 두어 순위와 관련성을 보다 더 반영하는 모델을 만들어 보다 더 정확하고 맥락에 맞는 결과를 생성할 수 있도록 하여 최종적으로 **모델의 성능을 향상시키고자 함**.

선행 연구

선행 연구

성능 개선을 위한 연구

Generator

- 제너레이터의 **모델의 크기가 클수록 더욱 뛰어난 답변으로 변환**할 수 있다는 점에 초점을 맞추어 연구
- RAG 모형의 계산 복잡도를 고려하여 훨씬 더 다양한 패시지들을 활용할 수 있도록 제너레이터를 구성
 - FiD, Fid-Distill, Atlas 등이 대표적인 연구


Retrieval

- 아무리 뛰어난 제너레이터 (언어 모형)을 사용하더라도 리트리버가 선택한 **패시지의 품질**이 최종 성능에 영향을 미친다는 점에 중점을 두어 연구
- 리트리버의 성능이 더 좋은 답변을 생성하는 데 더 필수적이라는 점을 강조
- Reranker, Contrieval, Dual-Encoder 등이 대표적인 연구

선행 연구

Why Fusion in Decoder?


- Retriever에서 추출한 모든 top-k 문단에 대하여 question과 함께 인코더의 input으로 넣음.
- Encoding된 벡터들을 **concat한 벡터를 디코더에 input으로 넣어** 최종 답변을 생성 (T5 사용).
- Passage의 개수가 많아지더라도 concat을 하니 계산 비용 감소.
 - RAG 같은 경우는 각각의 조합에 대해서 output을 생성 후 Beam Search 진행 -> Beam size가 크면 계산 증가.
- Special token인 [question:], [title:], [context:]을 두어 **[question:] 질문 토큰들, [title:] passage 제목 토큰들, [context:] passage 문맥 토큰들**의 구조로 인코더의 각 문단들을 넣음.



선행 연구

Why Fusion in Decoder?

- 현재 기준으로 파라미터가 매우 적게 느껴지는 T5 모델을 사용했음에도 NLP tasks에서 우수한 성능을 보임.
 - 논문 발표일(2021년) 기준 TriviaQA SoTA 달성.
- FiD 논문 발표 이후 현재까지 다양한 RAG 기반의 모델들이 FiD의 기본 구조를 baseline으로 두고 실험을 진행.
- Passage의 순서에 따라 가중치를 명시적으로 부여하는 것이 모델의 성능을 올리는지 보기위한 가장 적합한 baseline 모델이라 판단됨.
 - 리트리버 까지 학습되는 구조의 모델을 사용하면 GPU 메모리 제한.



연구 내용

연구 내용

연구 핵심

FiD 모델을 베이스라인으로 **패시지 순위(ranking)에 따라 가중치를 차등 부여**하는 방법론을 제안하여, 답변 생성 과정에서 **더 중요한 패시지가 큰 영향**을 미치도록 명시적으로 설정하여 전반적인 모델의 성능을 향상

01

인코더 연산이 끝난 후, 각 가중치들을 representation vector
에 곱한 뒤 concat하여 디코더로 전달


02

패시지 순위 (랭킹)에 따라 가중치 부여

- 세가지의 가중치 방법론을 적용하여 각각 실험 결과를 비교
- 순위가 높은 패시지 일수록 더 높은 가중치를 설정

연구 내용

- FiD 모형과 똑같은 형식으로 각 question과 passage 조합을 언어모형 인코더를 통해 representation vector 생성.
- 모든 조합들을 concat해서 디코더로 전달하기 전, **가중치**를 각 representation vector에 **곱하여** passage ranking이 높은 순대로 모델이 더 집중 하도록 유도.



연구 내용


가중치 방법론 1

- 상위 K 개의 패시지에 대해서 0.95 제곱의 가중치를 부여
- 첫 번째 패시지에 0.95의 0승, 두 번째는 0.95의 1승, ..., k 번째 패시지에는 0.95의 k-1 승으로 가중치를 명시적으로 설정
- 패시지 랭킹에 따라 점진적으로 감소하는 가중치를 부여

$$\text{vector} = [0.95^0, 0.95^1, 0.95^2, 0.95^3, \dots, 0.95^{k-1}]$$

K	가중치
1	1
2	0.95
3	0.9025
4	0.8573
5	0.8145
6	0.7737
7	0.7350
8	0.6983
9	0.6634
10	0.6302

K	가중치
11	0.5987
12	0.5688
13	0.5403
14	0.5133
15	0.4876
16	0.4632
17	0.4401
18	0.4181
19	0.3972
20	0.3773



연구 내용


가중치 방법론 2

- 자연로그 함수를 사용하여 가중치가 초반에는 급격하게 줄어듦, 뒤로 갈수록 천천히 감소하는 가중치 적용
- 첫 번째 패시지는 가중치를 1로 설정한 후, 아래의 공식을 적용하여 가중치 설정

$$\text{Value} = \frac{1}{1 + 0.1 \cdot \ln(k)}$$

K	가중치
1	1
2	0.9351
3	0.9010
4	0.8782
5	0.8613
6	0.8480
7	0.8371
8	0.8278
9	0.8198
10	0.8128

K	가중치
11	0.8065
12	0.8009
13	0.7958
14	0.7911
15	0.7869
16	0.7829
17	0.7792
18	0.7757
19	0.7725
20	0.7694



연구 내용


가중치 방법론 3

- 자연상수 e 를 사용하여 가중치가 초반에는 천천히 줄어들고, 뒤로 갈수록 급격히 감소하는 가중치 적용
- 첫 번째 패시지는 가중치를 1로 설정한 후, 아래의 공식을 적용하여 가중치 설정

$$\text{Value} = e^{-0.001 \cdot (k-1)^2}$$



K	가중치
1	1
2	0.9990
3	0.9960
4	0.9910
5	0.9841
6	0.9753
7	0.9646
8	0.9521
9	0.9380
10	0.9221

K	가중치
11	0.9048
12	0.8860
13	0.8658
14	0.8445
15	0.8220
16	0.7985
17	0.7741
18	0.7490
19	0.7232
20	0.6969



연구 내용

가중치 비교 그래프



연구 내용

베이스라인 (FiD) vs. 가중치 적용 모델


- FiD 논문에서 저자들이 중심으로 실험한 **TriviaQA, NQ** (Natural Questions) task를 놓고 두 모델의 성능 비교.
- FiD에서 사용한 동일한 리트리버와 제너레이터 사용 (t5-large 모델은 DA 서버 메모리 초과로 사용 불가).
- FiD 논문에서는 최대 100개의 passage들을 사용하였지만, 메모리 문제로 인해 최대 **20개의 패시지**까지 사용가능.
- 동일한 리트리버, 제너레이터, 하이퍼파라미터, 그리고 패시지 개수로 두 모델을 실험하여 최종 결과를 비교.
 - FiD 논문에서는 batch_size를 64로 하여 실험을 진행했지만, 메모리 제약상 batch_size를 2로 설정하여 학습 진행.

K_Passages	batch_size	Generator model	Learning Rate	Text_maxlength
20	2	T5 (base)	0.0005	250

연구 결과


연구 내용

성능 비교 (Baseline vs 방법론 1 가중치 모델)




연구 내용

성능 비교 (Baseline vs 방법론 2 가중치 모델)



연구 내용

성능 비교 (Baseline vs 방법론 3 가중치 모델)




연구 내용

성능 비교 with EM(Exact Match)

*m = Methodology (방법론)

Model	Trivia QA	Natural Questions
FiD	57.6	35.4
FiD + m1	58.69	36.54
FiD + m2	58.77	38.28
FiD + m3	58.73	38.03



결론

결론

Conclusion and Limitation

- Semi-Parametric 모형인 RAG에 등장이후 다양한 연구들이 전체적인 성능을 올리기 위해 연구를 진행.
 - 제너레이터 부분과 리트리버 부분을 중심으로 연구.
- 본 연구는 패시지에 더욱 더 중점을 두어 패시지의 중요도를 반영하기 위해 세 가지 가중치 부여 방안을 제안하고, 각 방법론들이 실제 모델의 성능을 올리는지 평가 진행.
 - 파라미터의 개수를 늘리지 않고 baseline 보다 Trivia, NQ task 성능을 향상시킴.
- GPU 메모리 제약상 FiD 저자들과 동일한 환경에서 실험불가.
 - Batch size, passage 사용 개수, t5-large 모델.
- 추가 연구를 진행 시, 두 가지 task 이외에도 다양한 task를 실험하여 FiD와 비교.