

실무 프로젝트 · 엘림넷 나우앤서베이

설문 교차분석 · 통계 분석 모듈

Survey Cross-tab & Statistical Analysis Engine

정제되지 않은 설문 응답 원본을 분석 가능한 형태로 정규화하고,
교차분석 · 상관 · 집단비교 · 회귀 · 의사결정나무를 비전문가가 실행할 수 있게 만든 분석 엔진

Flask · pandas · scipy · scikit-learn

Type Inference


Forward Stepwise

CART

LLM Interpretation

무엇을 만들었나

설문 응답 원본에서 출발해 정규화하고, 다섯 종류의 통계 분석을 실행한 뒤 결과를 자연어로 해설하는 백엔드 엔진.



≡ 응답 요약 ≡ 통계 분석 ^ 교차 분석 상관 분석 집단 비교 회귀 분석 의사결정 나무 🗨 개별 응답	교차 분석	카이제곱(χ^2) 독립성 검정	다중응답 · 최대 3변수 결합 지원
	상관 분석	피어슨 상관계수 행렬	페어와이즈 결측 처리
	집단 비교	Welch t-검정 / 일원배치 ANOVA	그룹 수에 따라 자동 분기
	회귀 분석	선형 / 로지스틱 회귀	전진 단계적 선택으로 조합 추천
	의사결정 나무	CART (Gini)	분기 임계값을 보기 라벨로 역매핑

설계 원칙 — 통계량은 전부 결정론적으로 계산한다. LLM은 이미 계산된 수치를 설명할 뿐, 숫자를 만들지 않는다.

PROBLEM

설문 응답 원본은 통계 라이브러리에 바로 들어가지 않는다

한 문항이 여러 컬럼에 흩어지고, 유형마다 셀 값의 의미가 달라 그대로는 `scipy · sklearn`에 넘길 수 없다.

! 다층 헤더 · 가변 구조

질문행 / 서브질문행 / 보기행 / 코드행이 겹쳐 있고, 설문마다 헤더 행 수가 다르다. 헤더가 몇 행인지부터 알아내야 한다.

! 한 문항 = 여러 컬럼

다중응답은 보기별로, 순위형은 순위별로, 매트릭스는 (행 × 열)로 컬럼이 쪼개진다. Q3_1_2 같은 코드에서 문항 단위를 복원해야 한다.

! 유형마다 다른 값의 의미

단일선택은 보기 번호, 다중응답은 선택 여부, 순위형은 순위, 척도형은 점수. 같은 숫자 1이 유형에 따라 전혀 다른 뜻이다.

! 결측의 이중 의미

다중응답에서 빈 셀은 “이 보기를 안 골랐다”일 수도, “문항 자체에 응답하지 않았다”일 수도 있다. 둘을 구분하지 않으면 분모가 틀어진다.

! 중복 코드 · 기타 입력란

같은 코드가 두 번 등장하면 두 번째는 기타 텍스트 입력란이다. 이걸 분석 대상 컬럼과 섞으면 집계가 깨진다.

! 비전문가 사용자

결과를 보는 사람이 통계 비전문가다. p값과 임계값을 던져주는 것으로는 부족하고, 읽는 법까지 제공해야 한다.

수집 경로 참고 — 프로토타입은 엑셀 리더로 응답 원본을 읽지만, 실서비스에서는 동일한 정규화 로직이 설문 응답 raw 데이터에 그대로 적용된다.

정규화 파이프라인

응답 원본 2차원 배열을 tidy DataFrame과 메타데이터 딕셔너리 두 개로 분해한다.

1 코드 행 자동 감지

상위 6행을 훑어 `^Q\d+` 정규식이 처음 매칭되는 행을 코드 행으로 확정. 헤더 깊이를 가정하지 않는다.

2 헤더 구조 역산

코드 행 인덱스 기준으로 -3 -2 -1을 질문 · 서브질문 · 보기 행에 배정. 3행 · 2행 헤더는 별도 폴백 분기.

3 컬럼 코드 유니크화

중복 코드에 `_otherTextN` 접미사 부여. 두 번째 등장은 기타 텍스트 입력란으로 분리 보관.

4 문항 단위 그룹핑

Q3_1_2 → 정규식으로 `base_qid` Q3 추출. 흩어진 컬럼을 `OrderedDict`로 문항 단위 묶음 복원.

5 유형 판별

`determine_type()` — 키워드 → 코드 패턴 → 데이터 값 분포 3단계 폴백.

6 타입별 정규화

유형마다 다른 규칙으로 분석용 컬럼 생성 + meta 기록. 컬럼명 충돌은 (2), (3) 자동 부여.

OUTPUT — DataFrame

분석용 컬럼만 남은 tidy 형태.
문항 하나가 유형에 따라 1개 또는 N개 컬럼으로 표현된다.

OUTPUT — meta (OrderedDict)

`title · type · columns · options · option_to_num`
`num_to_option · raw_codes · extra_columns`

문항 유형 자동 판별 — 3단계 폴백

문항 텍스트를 믿을 수 없을 때는 코드 패턴을, 그것도 없으면 데이터 값 분포를 보고 유형을 역추론한다.

1 단계 · 키워드 매칭

문항 텍스트에 유형명이 들어 있는 경우를 40여 개 키워드 테이블로 잡는다. 매칭 순서가 중요해서 “NPS 복수”를 “NPS”보다 앞에 두었다. 부분 문자열 매칭이라 순서가 곧 우선순위다.

2 단계 · 코드 패턴

$^Q\backslash d+_ \backslash d+_ \backslash d+ \$$ 형태면 매트릭스 문항으로 판정하고, 셀 값이 숫자인지 문자인지로 matrix_multi / matrix_text를 가른다. 코드에 “파일”이 들어가면 파일 업로드 문항.

3 단계 · 데이터 값 분포

$_N$ 서브코드가 여러이면 실제 값을 본다. 모든 값이 1.0이면 다중응답, k번째 컬럼 값이 전부 k+1인 자기참조 패턴도 다중응답, 값이 1..보기수 정수면 순위형, 나머지는 숫자 복수형.

4 폴백

단일 컬럼이면 보기 텍스트를 본다. 라벨이 있으면 단일선택, 숫자뿐이면 척도형. 보기 자체가 없으면 값을 숫자 캐스팅해보고 성공하면 numeric, 실패하면 주관식(open).

판별 결과 타입

single	scale
multi	rank
numeric	numeric_multi
scale_multi	matrix_single
matrix_multi	matrix_numeric
matrix_text	open

왜 폴백 구조인가

실서비스 설문은 작성자가 자유롭게 만든다. 문항 텍스트에 유형명이 없거나, 같은 유형인데 코드 패턴이 다른 경우가 흔하다. 어느 한 단서만 믿으면 유형 판별이 깨지므로, 신뢰도 순으로 단서를 쌓고 마지막에는 데이터 자체를 근거로 삼았다.

타입별 정규화 규칙

판별된 유형마다 분석용 컬럼을 만드는 방식이 다르다. 여기서 만든 구조를 다섯 분석기가 공유한다.

single

응답 코드(1..N)를 보기 라벨 문자열로 매핑해 1개 컬럼 생성. option_to_num / num_to_option 양방향 딕셔너리를 meta에 함께 보관해, 이후 어떤 분석에서든 라벨↔번호를 되돌릴 수 있게 했다.

scale

숫자 값 그대로 유지하고 scale_range(1, 보기수)를 기록. 보기 텍스트가 없으면 (1, 11)로 두어 NPS를 포괄한다.

multi

보기별 0/1 더미 컬럼을 만든다. 핵심은 결측 처리다 — 어떤 보기도 고르지 않은 응답자는 0이 아니라 NaN으로 채워, “안 골랐다”와 “응답 자체를 안 했다”를 분리했다.

rank

순위별 컬럼을 만들고 최대 순위를 min(데이터 최대값, 보기 수)로 클램프. 데이터가 비면 보기 수로 폴백해 KeyError를 원천 차단했다.

matrix

(소질문 × 보기) 조합으로 컬럼을 펼치고 첫 소질문을 대표 카테고리로 삼는다. 교차분석에서는 첫 행만 사용한다.

컬럼명 충돌 처리

`_add_col()`

같은 제목의 문항이 반복될 때

“제목 (2)”, “제목 (3)”으로 자동 넘버링.

원본 설문에서 문항 제목 중복은 흔해서, 이걸 막지 않으면 컬럼이 덮어써진다.

기타 텍스트 분리

`_기타 코드` 또는 `_otherText` 접미사가 붙은 컬럼은 `extra_columns`로 따로 뺀다.

분석 대상 컬럼에 섞이면 다중응답 보기 수가 부풀고 집계 분모가 틀어진다.

분석기가 유형을 몰라도 되게 만드는 계층

다섯 개 분석기가 각자 유형 분기를 갖지 않도록, 수치화와 결측 처리를 한 곳에 모았다.

get_numeric_series(qid)

어떤 문항 유형이든 (응답자 index → float) 형태의 pandas Series 하나로 변환한다.

single · rank	보기 라벨 → 보기 번호로 역매핑
multi	가장 앞선 선택 보기의 번호를 대표값으로 (더미 컬럼 순회, 이미 채워진 응답자는 건너뛰)
scale · numeric	값 그대로 float 캐스팅
matrix	첫 소질문 응답을 1..N으로 매핑

중복 index 방어

반환 직전 `s[s.index.duplicated(keep="first")]`로 중복 응답자 인덱스를 제거한다. 매트릭스나 복수형 문항에서 인덱스가 중복되면 이후 intersection 연산이 조용히 행을 부풀리기 때문에, 유입 지점에서 막았다.

결측 처리 — Pairwise Deletion

모든 분석은 사용할 변수들의 index를 intersection해서 공통 응답자만 남긴 뒤 계산한다. 문항 하나가 비었다고 응답자 전체를 버리지 않고, 그 분석에 필요한 변수만 기준으로 판단한다.

같은 설문에서도 분석마다 유효 N이 달라지므로, 결과에는 항상 그 분석의 N을 함께 반환한다.

이 계층이 있어서 가능해진 것

- 분석기 코드에서 유형 분기가 사라진다
- 새 문항 유형 추가 시 수정 지점이 한 곳
- 회귀 · 트리에 넣을 X 행렬을 균일하게 조립
- 유효 N 계산 로직이 분석마다 흩어지지 않는다

교차 분석 — 카이제곱 독립성 검정

다중응답과 변수 결합을 지원하기 위해, 교차표 생성 자체를 직접 구현했다.

1 응답 형태 이원화

단일선택 · 척도형은 스칼라를, 다중응답 · 순위형은 선택 번호 리스트를 반환한다. 이후 로직은 스칼라도 길이 1 리스트로 승격시켜 하나의 경로로 처리한다.

2 다중응답 교차 카운팅

한 응답자가 행 2개 · 열 3개를 골랐다면 6개 조합 셀을 모두 증가시킨다. 그래서 교차표 합계가 응답자 수 N 을 초과할 수 있고, 이 점을 결과 해석에 명시한다.

3 변수 결합 (최대 3개)

`itertools.product`로 여러 변수의 카르테시안 조합을 만들어 “남성 / 20대 / 학생” 같은 가상 변수 하나로 취급한다. `combo` → `index` 매핑으로 결합 변수도 동일한 교차표 코드를 태운다.

4 빈 행 · 열 트리밍

합이 0인 행과 열을 `np.ix_`로 먼저 잘라낸 뒤 `chi2_contingency`에 넘긴다. 자르지 않으면 기대빈도 0으로 검정이 예외를 던진다. 잘라낸 뒤 2×2 미만이면 검정을 건너뛰고 $\chi^2=0$, $p=1$ 로 반환한다.


5 표준화 잔차

$(\text{관측} - \text{기대}) / \sqrt{\text{기대}}$ 를 기대빈도가 양수인 셀에서만 계산하고, 원래 `shape`에 되채워 폰트가 셀 색으로 “기대보다 높음 / 낮음”을 표시할 수 있게 했다.

결과 반환: χ^2 · df · p · 관측표 · 기대표 · 표준화 잔차 · N · 행 라벨 · 결합 여부 · AI 해석

교차 분석 화면

문항을 분석 기준 · 분석 대상으로 끌어다 놓으면 결합 변수가 만들어지고, 번들 단위로 검정이 실행된다.



드래그앤드롭 설정 — 분석 기준(행) 여러 변수를 한 묶음으로 결합

Q4. 전 직급 근무연수 [제한식(단일)]									
				1년 미만	1~3년	3~5년	5~10년	10년 이상	합계
Q4. 전 직급 근무연수 [제한식(단일)]	배우 근무연수	소속부서	소속부서 없음(5000)	0	2	2	0	1	5
			종사기간	1	5	4	2	1	13
			종교기간	1	0	3	3	1	8
			내거기간	1	2	0	1	0	4
	불만족	소속부서 없음(5000)	소속부서 없음(5000)	2	4	7	3	0	16
			종사기간	8	4	6	8	7	33
			종교기간	8	12	8	5	4	37
			내거기간	6	8	7	4	3	28
	보통	소속부서 없음(5000)	소속부서 없음(5000)	5	8	3	4	5	29
			종사기간	16	11	17	15	7	66
			종교기간	10	20	12	12	3	57
			내거기간	6	9	10	9	5	39
Q4. 전 직급 근무연수 [제한식(단일)]	만족	소속부서 없음(5000)	소속부서 없음(5000)	6	4	5	4	2	21
			종사기간	9	12	13	10	2	46
			종교기간	4	6	5	5	7	27
			내거기간	7	5	6	7	6	31

설문 교차분석 · 통계 분석 모듈



번들별 $\chi^2 \cdot df \cdot p$ 와 AI 해석

번들 단위 검정

분석 기준 묶음마다 독립적으로 카이제곱을 돌린다. 결합 변수 묶음과 단일 변수 묶음이 한 화면에서 함께 비교된다.

빈도 / 비율 / 비율%(빈도)

같은 교차표를 세 가지 표기로 전환한다. 표기 전환은 프론트에서 처리하고 서버는 관측표만 내려준다.

유의수준 선택

95% 등 유의수준을 바꾸면 잔차 하이라이트 기준이 함께 바뀐다.

상관 분석 — 피어슨 상관계수 행렬

쌍마다 유효 응답자가 다르므로, 행렬 전체가 아니라 쌍 단위로 결측을 처리한다.

1 대상 제한

척도형 · 순위형만 허용하고 명목형 문항은 UI에서 비활성화한다. 순서가 없는 범주에 피어슨을 적용하면 계수는 나오지만 의미가 없기 때문이다.

2 쌍 단위 교집합

각 변수쌍마다 두 Series의 index를 intersection해 공통 응답자만 사용한다. 표본이 3명 미만인 쌍은 계산을 건너뛴다.

3 상삼각 계산 후 대칭 복사

$j > i$ 영역만 계산하고 (i,j) 와 (j,i) 에 동시에 대입한다. 계산량을 절반으로 줄이면서 대칭성을 코드로 보장한다.

4 직렬화 방어

NaN이 하나라도 남으면 JSON 직렬화가 실패한다. 반환 직전 r 은 0, p 는 1로 치환해 프론트가 항상 렌더가 가능한 행렬을 받도록 했다.

상관 분석

척도/순위형 변수들 간의 상관관계를 피어슨 상관계수(r)로 분석합니다.

분석 설정

분석할 문항을 선택하세요 (척도형 문항만 가능, 2개 이상)

Q1 성별 [척도형(단일)] ☐ Q2 연령대 [척도형(단일)] ☐ Q3 직업 [척도형(단일)] ☐ Q4 현재 직업 만족도 [척도형(단일)] ☐ Q5 회사 규모 [척도형(단일)] ☐ Q6 현재 업무 만족도 [척도형] ☒ Q7 급여보상 만족도 [척도형] ☒ Q8 워라밸(일-생활 균형) 만족도 [척도형] ☒ Q9 상사/동료 관계 만족도 [척도형] ☒ Q10 상사/생전 가능성 만족도 [척도형] ☐ Q11 직장 선택 시 중요하게 생각하는 요소... ☐ Q12 이직을 고려하게 되는 이유 [순위형...] ☐ Q13 향후 1년 내 이직 의향 [척도형(단일)] ☐

초기화

분석 실행

피어슨 상관계수 히트맵



열 viewer 시 읽제 수치 표시

AI 해석

상관관계 히트맵은 각 변수쌍이 서로 얼마나 밀접하게 연관되어 있는지를 색으로 보여줍니다. 색이 짙은 파란색은 동일수준 두 변수가 함께 오르내리는 강한 긍정적 관계를, 짙은 자갈은 동일수준 한 변수가 오를 때 다른 변수는 내려가는 강한 부정적 관계를 나타냅니다. 여기서는 워라밸(일-생활 균형) 만족도와 상사 및 동료와의 관계 만족도가 상관계수 0.73으로 매우 강하게 연관되어 있습니다. 이는 직장에서 상사와 동료와의 관계가 좋다고 느낄수록 일과 삶의 균형에도 큰 만족을 느끼는 경향이 있음을 뜻합니다. 전체적으로 보면, 이 두 요소는 서로 간접하게 영향을 주고받으면서 조직 내 만족감을 크게 좌우한다는 점을 알 수 있습니다.

히트맵과 함께 4~6문장 분량의 AI 해석을 제공해, 계수 숫자를 읽는 법까지 안내한다.

집단 비교 — 검정 자동 분기

사용자가 검정 기법을 고르지 않는다. 유효 그룹 수를 세어 시스템이 t-검정과 ANOVA를 선택한다.

유효 그룹 2개

Welch t-검정

`equal_var=False`로 등분산 가정을 두지 않는다. Welch-Satterthwaite 자유도를 직접 계산해 표시하고, 효과크기는 합동 표준편차 기반 Cohen's d로 산출한다.

다중응답 그룹 변수

그룹 변수가 다중응답이면 더미 컬럼(==1)을 직접 참조해 그룹을 만든다. 한 응답자가 여러 그룹에 동시에 포함되며, 전체 기준선은 “하나라도 선택한 응답자”로 잡는다.

유효 그룹 3개 이상

일원배치 ANOVA

`f_oneway`로 F와 p를 얻고, SSB · SSW · SST를 직접 계산해 η^2 를 구한다. 효과크기 해석 임계(0.06 / 0.14)를 코드에 명시해 “중간 효과” 같은 라벨을 함께 반환한다.

시각화용 원자료 동봉

그룹별 n · 평균 · 표준편차 · 표준오차에 더해 사분위(min · Q1 · 중앙값 · Q3 · max · IQR)와 원자료 배열을 함께 반환한다. 프론트는 이것으로 KDE 밀도곡선과 박스플롯을 동시에 그린다.

왜 사용자에게 검정을 고르게 하지 않았나

검정 선택은 통계 지식이 필요한 결정이고, 잘못 고르면 결과 자체가 무효가 된다. 그룹 수와 표본 조건은 데이터에서 이미 알 수 있으므로, 판단을 사용자에게 넘기지 않고 시스템이 결정한 뒤 “무엇으로 검정했는지”를 결과에 명시하는 쪽을 택했다.

집단 비교 화면

집단 구분 변수를 고르면 보기 수에 따라 어떤 검정이 적용될지 UI에 미리 표시된다.

집단 비교

집단 구분 변수에 따라 종속 변수의 평균 차이를 t-검정 또는 분산분석(ANOVA)으로 검증합니다.

분석 설정

집단 구분 변수 보기 2개 → 독립표본 t-검정

Q1. 성별 [객관식(단일)]

종속 변수 그룹 변수 선택 후 활성화

Q1 성별 [객관식(단일)]

Q2 연령대 [객관식(단일)]

Q3 직군 [객관식(단일)]

Q4 현 직장 근무연수 [객관식(단일)]

Q5 회사 규모 [객관식(단일)]

Q6 현재 업무 만족도 [척도형]

Q7 급여/보상 만족도 [척도형]

Q8 워라벨(일-생활 균형) 만족도 [척도형]

Q9 상사/동료 관계 만족도 [척도형]

Q10 성장/발전 가능성 만족도 [척도형]

Q11 직장 선택 시 중요하게 생각하는 요소...


Q12 이직을 고려하게 되는 이유 [순위 선택]

Q13 향후 1년 내 이직 의향 [객관식(단일)]

초기화

분석 실행

집단 구분 변수 선택 시 “보기 2개 → 독립표본 t-검정”을 사전 안내



밀도 분포 + 박스플롯

같은 데이터를 분포 형태와 요약 통계 두 관점으로 동시에 보여준다. 평균만으로는 두 집단의 분포 모양 차이가 드러나지 않기 때문이다.

검정 결과 요약 바

검정 이름 · 통계량 · 자유도 · p값 · 유의 여부를 한 줄로 고정 표시한다.

집단별 기술통계 표

n · 평균 · 표준편차를 그룹별로, 그리고 전체 행까지 함께 제공해 기준선을 잡을 수 있게 했다.

AI 해석

“수치 차이는 있지만 체감 차이는 크지 않을 수 있다”처럼, 유의하지 않은 결과를 과대 해석하지 않도록 문장을 유도한다.

회귀 분석 — 모델 자동 선택과 조합 탐색

종속변수 타입으로 모델을 고르고, 독립변수 조합은 전진 단계적 선택으로 탐색한다.

모델 자동 분기

종속변수가 척도형이면 선형 회귀, 범주형이면 로지스틱 회귀로 분기한다. 사용자는 “무엇을 예측할지”만 고르고 모델 선택은 하지 않는다.

1 후보 필터링

종속변수 자신과 주관식(open)을 제외하고, 유효 응답이 10건 미만인 문항도 후보에서 뺀다.

2 전진 선택 루프

매 스텝마다 남은 후보를 하나씩 추가해보고 가장 좋은 하나를 채택한다. 선형은 MSE 최소, 로지스틱은 정확도 최대가 기준이다.

3 조기 종료

이번 스텝의 최적값이 직전 최적값을 개선하지 못하면 즉시 멈춘다. 최대 조합 크기는 5로 제한해 탐색 폭발과 과적합을 함께 막았다.

한계 명시 — 정확도는 학습 데이터 기준이며 홀드아웃 검증이 아니다.

선형 회귀 — 직접 구현한 산출값

np.linalg.lstsq로 정규방정식을 풀고
 $R^2 \cdot \text{adj } R^2 \cdot F \cdot p(F) \cdot \text{MSE} \cdot \text{RMSE}$ 산출.
 $\text{SE}(\beta) = \sqrt{\text{diag}(\text{MSE} \cdot (X^T X)^{-1})}$ 로 계수별
 표준오차 $\rightarrow t \rightarrow p$ 를 계산하고,
 표준화 계수($\beta \cdot \text{sd}_x / \text{sd}_y$)와 VIF까지 함께 반환한다.

로지스틱 회귀

sklearn LogisticRegression(max_iter=500, random_state=42).
 LabelEncoder로 범주를 인코딩하고 이진 / 다항을 분기.
 계수 B와 오즈비 $\exp(B)$ 를 함께 제공하며,
 클래스별 로짓 공식을 문자열로 생성해
 프론트에서 수식으로 렌더한다.

종속변수를 고르는 순간 BEST 조합이 미리 계산되어 카드로 제시된다.

회귀 분석

독립변수가 종속변수에 미치는 영향을 선형 회귀 모형으로 분석합니다.

분석 설정

종속 변수 (Y) 범주형 → 로지스틱 회귀분석

Q2. 연령대 [객관식(단일)]

BEST 조합 추천 — 클릭하면 자동 선택 후 분석 실행

로지스틱

$$P = \frac{1}{1 + e^{-(0.9551 - 0.0636Q8 - 0.0458Q12 - 0.1114Q9 - 0.0032Q6)}}$$

정확도 43.8% · 변수 20대, 30대, 40대, 50대 이상

독립 변수 (X) 전체 문항 선택 가능

Q1 성별 [객관식(단일)]

Q2 연령대 [객관식(단일)]

Q3 직군 [객관식(단일)]

Q4 현 직장 근무연수 [객관식(단일)]

Q5 회사 규모 [객관식(단일)]

Q6 현재 업무 만족도 [척도형]

Q7 급여/보상 만족도 [척도형]

Q8 워라밸(일-생활 균형) 만족도 [척도...]

Q9 상사/동료 관계 만족도 [척도형]

Q10 성장/발전 가능성 만족도 [척도형]

Q11 직장 선택 시 중요하게 생각하는 요소...

Q12 이직을 고려하게 되는 이유 [순위 선택...]

Q13 향후 1년 내 이직 의향 [객관식(단일)]

초기화

분석 실행

BEST 조합 추천 카드 — 클릭하면 해당 조합으로 자동 선택 후 분석 실행

모지스틱 하위분석 결과

④ A 세제

모지스틱 결과는 여타 예측 변수들을 제로값으로 만들었기 기는, 값단체 속할 확률을 각각 계산하여, 주로 결과는 모지스틱(하위)를 제공함니다. 모지스틱이 1보다 크면 해당 변수가 그 영향력에 속할 가능성이 높았고, 1보다 작으면 가능성이 낮습니다. 분석 결과 하위별 분석에는 3개의 하위영향으로 모지스틱이 1보다 높고, 모지스틱이 높을수록 이 영향력에 속할 확률이 커지는 경향이 있습니다. 반면 하위 1과 2에서는 해당 영향력은 모지스틱이 1보다 낮아, 상대적으로 낮은 영향력 특성이 나타나며, 이는 상대적으로 낮은 영향력을 나타내는 것으로 해석됩니다. 일-생활 균형에 대한 분석도가 전반적 구간에 중립적 단서가 될것 예상합니다.

43.2%	500	3	4
여학생	남자 - 여학생	의심만 - 주	남주 - 주

방수 - 2018

공식

$$\ln\left(\frac{P_{\text{방수}}}{1 - P_{\text{방수}}}\right) = 0.7593 + 0.0733 \cdot Q_8 - 0.1170 \cdot Q_9 + 0.0264 \cdot Q_{10}$$

$$P(\text{방수} = 2018) = \frac{1}{1 + e^{-(0.7593 + 0.0733 \cdot Q_8 - 0.1170 \cdot Q_9 + 0.0264 \cdot Q_{10})}} \quad [\text{vs } 1-\text{비치}]$$

방수	B (방수=주)	OZS (방수 = OZS)
(방수)	-0.7593	2.3357
Q8, 방수열(M-생활 균형) 방수열 [최도형]	-0.0733	0.9239
Q9, 방수/물류 관계 방수열 [최도형]	-0.1170	0.8859
Q10, 방수방수 가능성 방수열 [최도형]	0.0264	1.0279

13개 문항에서 독립변수 조합을 고르는 것은 비전문가에게 사실상 불가능한 선택이다. 탐색을 서버가 대신 수행하고, 사용자는 결과를 받아들이거나 직접 조정한다.

로짓 공식과 확률 공식을 KaTeX로 렌더해 어떤 계수가 어떻게 곱해지는지 보이게 했다. 블랙박스도 두지 않는 것이 신뢰에 유리하다고 판단했다.

OR > 1인 변수는 색으로 구분해, 계수 부호를 해석하지 못해도 방향은 읽히도록 했다.

정확도 · 표본수 · 독립변수 수 · 범주 수를 상단에 고정해 모델의 전제를 먼저 보게 했다.

의사결정 나무 — CART와 라벨 역매핑

트리를 만드는 것보다, 만들어진 트리를 비전문가가 읽게 만드는 쪽에 더 많은 코드가 들어갔다.

1 데이터 크기 비례 하이퍼파라미터

`max_depth=10` 고정에 더해 `min_samples_split`은 $\max(20, 5\%N)$, `min_samples_leaf`는 $\max(10, 2\%N)$ 로 잡았다. 표본이 작을 때 리프가 한 두 명으로 쪼개지는 과분할을 막는다.

2 sklearn 버전 호환 처리

1.3부터 `tree.value`가 실제 개수가 아니라 비율(합=1)로 바뀌었다. `weighted_n_node_samples`를 곱해 정수 개수로 복원한 뒤 클래스 분포를 만든다. 버전 차이를 그대로 두면 노드 인원수가 전부 0으로 표시된다.

3 분기 임계값 → 보기 라벨 역매핑

CART가 고른 `threshold 3.5`를 그대로 보여주면 아무도 못 읽는다. `floor`를 취해 보기 번호로 바꾸고 `meta`의 옵션 라벨을 붙여 " ≤ 3 번 (보통)" / "> 3번 (만족)"으로 변환한다. 척도형과 단일선택에서 라벨 표기를 다르게 처리한다.

4 노드 페이로드 구성

리프마다 `n · 다수 클래스 · 클래스별 분포 · 순도 · Gini`를 담아 내려보내, 프론트가 각 노드에서 "몇 명이 어떻게 나뉘었는지"를 표시할 수 있게 했다.

5 Gini 변수 중요도

`feature_importances_`를 내림차순 정렬해 어떤 문항이 분류에 기여했는지 막대로 제공한다.

AI 변수 추천 — 목표 변수를 고르면 후보 문항 목록을 LLM에 넘겨 상위 3~5개와 추천 사유를 JSON 스키마로 강제 출력받는다.

의사결정 나무 화면

변수 추천 → 트리 시각화 → 변수 중요도까지 한 흐름으로 연결된다.

의사결정 나무

목표 변수를 가장 잘 예측하는 변수를 계속적으로 분류하여 트리 형태로 시각화합니다.

분석 설정

목표 변수: 객관식(단일)

Q3. 직군 [객관식(단일)]

예측 변수: 복수 선택

Q1. 성별 [객관식(단일)]

Q2. 연령대 [객관식(단일)]

Q3. 직군 [객관식(단일)]

Q4. 현 직장 근무연수 [객관식(단일)]

Q5. 회사 규모 [객관식(단일)]

Q6. 현재 입사 만족도 [척도형]

Q7. 급여/보상 만족도 [척도형]

Q8. 워라밸(일-생활 균형) 만족도 [척도형]

Q9. 상사/동료 관계 만족도 [척도형]

Q10. 성장/발전 가능성 만족도 [척도형]

Q11. 직장 선택 시 중요하게 생각하는 요소...

Q12. 이직을 고려하게 되는 이유 [순위 선택]

Q13. 향후 1년 내 이직 의향 [객관식(단일)]

시 변수 추천

직군을 예측하는 데 연령대, 회사 규모, 직장 선택 시 중요 요소 등이 큰 영향을 줄 수 있습니다.

1순위 Q2. 연령대

직군마다 주로 분포하는 연령대가 다를 수 있어 직군을 예측하는 데 도움이 됩니다.

2순위 Q5. 회사 규모

특정 직군이 선호하거나 많이 분포하는 회사 규모가 다를 수 있기 때문에 유의미한 변수입니다.

3순위 Q11. 직장 선택 시 중요하게 생각하는 요소

각 직군마다 직장 선택 기준이 다를 수 있어 직군을 구분하는 데 도움이 될 수 있습니다.

4순위 Q13. 향후 1년 내 이직 의향

이직 의향은 직군별로 차이가 있을 수 있어 직군을 예측하는 데 참고가 될 수 있습니다.

초기화

분석 상세

목표 변수 선택 시 시가 예측 변수 후보를 순위와 이유로 제시

요약 지표

표본 수 · 분류 수 · 최대 깊이 · 리프 노드 수를 상단에 고정

설문 교차분석 · 통계 분석 모듈

의사결정 나무 (CART)

예측 대상: Q3. 직군 [객관식(단일)]

1. 데이터셋 / 2. 예측대상/목표 / 3. 분할규칙 / 4. 결정사건 / 5. 분할변량

496 표본 수 / 5 분할 수 / 7 최대 깊이 / 22 리프 노드

변수 중요도 (Gini importance)

Q11. 직장 선택 시 중요하게 생각하는 요소 [...] 45.7%

Q10. 성장/발전 가능성 만족도 [척도형] 28.3%

CART 트리 · 노드별 n / 순도 / Gini / 클래스 분포와 Gini 변수 중요도

노드 색 구분

분기 노드와 예측 결과 리프를 색으로 나눠 트리 읽는 방향을 안내

가로 스크롤 트리

깊은 트리는 축소 대신 스크롤로 제공해 노드 텍스트 가독성을 유지

15

LLM은 숫자를 만들지 않는다

통계량은 전부 scipy · sklearn으로 결정론적으로 계산하고, LLM에는 계산이 끝난 수치만 넘겨 설명을 맡긴다.

1 통계 규칙을 프롬프트에 못박음

$p < 0.05$ 면 “통계적으로 유의하며 두 변수는 독립이 아니다”, $p \geq 0.05$ 면 “유의성이 확인되지 않았고 독립으로 볼 수 있다”로 결론 문장을 고정했다. 모델이 판정 기준을 스스로 정하지 못하게 한다.

3 출력 형식 제약

도입부 상투구 금지, 2~3문장 제한(상관분석은 4~6문장), 마크다운 · 기호 없이 완결된 한국어 문장만. 프론트가 그대로 렌더하므로 서식 문자가 섞이면 화면이 깨진다.

구조화 출력 강제

의사결정나무 변수 추천은 JSON 스키마를 지정해 응답받고, 파서에서 첫 { 와 마지막 } 사이만 잘라 파싱한다. 모델이 앞뒤에 설명을 붙여도 깨지지 않는다.

2 오해를 부르는 표현 금지

“우연히 발생했을 가능성” 같은 확률론적 서술을 명시적으로 금지했다. p값을 “우연일 확률”로 설명하면 잘못된 통계 이해를 심어주기 때문이다.

4 맥락 주입

두 문항의 원문 텍스트, N , χ^2 , df , p 를 사용자 프롬프트에 구조화해 넣는다. 결합 변수일 때는 “행이 여러 변수의 조합”이라는 설명을 추가로 주입해 해석이 어긋나지 않게 한다.

우아한 실패

LLM 호출을 try/except로 감싸고 실패하면 interpretation을 null로 반환한다. AI 해석이 죽어도 통계 결과는 그대로 표시된다 — 해석은 부가 기능이지 분석의 전제가 아니다.

정리

1

무엇을 만들었나

설문 응답 원본을 자동 정규화하고, 교차분석 · 상관 · 집단비교 · 회귀 · 의사결정나무 다섯 종을 실행해 결과를 자연어 해설과 함께 반환하는 분석 엔진.

2

어떤 문제를 풀었나

한 문항이 여러 컬럼에 흩어지고 유형마다 값의 의미가 다른 설문 데이터를 통계 라이브러리가 받을 수 있는 형태로 만드는 문제, 그리고 통계 비전문가가 결과를 읽게 만드는 문제.

3

어떻게 해결했나

유형 판별을 3단계 폴백으로 설계하고 수치화 계층을 하나로 모아 분석기에서 유형 분기를 없앴다. 검정 기법과 변수 조합은 시스템이 정하고, LLM은 계산된 수치의 해설만 맡겼다.

통계를 아는 사람만 쓸 수 있는 도구를, 설문을 만든 사람이면 누구나 쓸 수 있는 도구로 바꿨다.

Flask · pandas · numpy · scipy.stats · scikit-learn · 분석 5종 · 문항 유형 12종 대응